




ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE
Fakulta jaderná a fyzikálně inženýrská



**Název práce česky název práce česky název práce
česky název práce česky**

**Title of the Work in English Title of the Work in
English Title of the Work in English**

Bakalářská práce

Autor: **Jméno Autora**
Vedoucí práce: **prof. Ing. Jméno Školitele, DrSc.**
Konzultant: **doc. RNDr. Jméno Konzultanta, CSc.** (pouze pokud konzultant byl jmenován.)
Akademický rok: 2024/2025

I. OSOBNÍ A STUDIJNÍ ÚDAJE

Příjmení: Jméno: Osobní číslo:
Fakulta/ústav: **Fakulta jaderná a fyzikálně inženýrská**
Zadávací katedra/ústav:
Studijní program:
Specializace:

II. ÚDAJE K BAKALÁŘSKÉ PRÁCI

Název bakalářské práce:

Šablona

Název bakalářské práce anglicky:

Template

Pokyny pro vypracování:

1. první bod zadání
2. druhý bod zadání
3. atd.

**Místo tohoto souboru použijte
soubor PDF se všemi podpisy,
který lze stáhnout z KOS, resp.
jste jej obdrželi e-mailem.**

Seznam doporučené literatury:

- [1] reference č. 1
- [2] reference č. 2
- [3] atd.

Jméno a pracoviště vedoucí(ho) bakalářské práce:

prof. Ing. Jméno Školitele, DrSc.

Jméno a pracoviště druhé(ho) vedoucí(ho) nebo konzultanta(ky) bakalářské práce:

doc. RNDr. Jméno Konzultanta, CSc.

Datum zadání bakalářské práce: **31.10.2023**

Termín odevzdání bakalářské práce: **05.08.2024**

Platnost zadání bakalářské práce: **30.09.2025**

(jméno vedoucího - bude doplněno)
podpis vedoucí(ho) práce

(jméno vedoucího - bude doplněno)
podpis vedoucí(ho) ústavu/katedry

doc. Ing. Václav Čuba, Ph.D.
podpis děkana

III. PŘEVZETÍ ZADÁNÍ

Student bere na vědomí, že je povinen vypracovat bakalářskou práci samostatně, bez cizí pomoci, s výjimkou poskytnutých konzultací. Seznam použité literatury, jiných pramenů a jmen konzultantů je třeba uvést v bakalářské práci.

Datum převzetí zadání

Podpis studenta

Místo tohoto souboru použijte
soubor PDF se všemi podpisy,
který lze stáhnout z KOS, resp.
jste jej obdrželi e-mailem.

PROHLÁŠENÍ

Já, níže podepsaný

Příjmení, jméno studenta: John Doe
Osobní číslo: 123456
Název programu: Matematické inženýrství

prohlašuji, že jsem bakalářskou práci s názvem

... název práce ...

vypracoval samostatně a uvedl veškeré použité informační zdroje v souladu s Metodickým pokynem o dodržování etických principů při přípravě vysokoškolských závěrečných prací a Rámcovými pravidly používání umělé inteligence na ČVUT pro studijní a pedagogické účely v Bc a NM studiu.

Prohlašuji, že jsem v průběhu příprav a psaní závěrečné práce použil nástroje umělé inteligence. Vygenerovaný obsah jsem ověřil. Stvrzuji, že jsem si vědom, že za obsah závěrečné práce plně zodpovídám.

V Praze dne

John Doe

.....
podpis studenta

**Místo tohoto souboru použijte prohlášení
vygenerované a podepsané v systému KOS.**

Poděkování:

Chtěl bych zde poděkovat především svému školiteli za pečlivost, ochotu, vstřícnost a odborné i lidské zázemí při vedení mé diplomové práce. Dále děkuji svému konzultantovi za

Název práce

Studijní program: Celý název studijního programu (nikoliv zkratka)

Druh práce: Bakalářská práce

Vedoucí práce: prof. Ing. Jméno Školitele, DrSc., pracoviště školitele (název instituce, fakulty, katedry...)

Konzultant: doc. RNDr. Jméno Konzultanta, CSc., pracoviště konzultanta. Pouze pokud konzultant byl jmenován.

[illegible]

Klíčová slova: klíčová slova (nebo výrazy) seřazená podle abecedy a oddělená čárkou

Title:

Title of the Work

Author: Author's Name

[illegible]

Key words: keywords in alphabetical order separated by commas

Obsah

Úvod	12
1 Bayesovská statistika	13
1.1 Základní principy Bayesovské statistiky	13
2 Problematika výběru modelů	14
2.1 Obecný princip hledání modelu	14
2.2 Bayesův přístup k výběru modelu	15
2.3 GP regrese	16
2.4 Výběr modelu pro GP regresi	18
2.4.1 Variační inference	18
2.4.2 Type II – MLE	18
2.4.3 Markov Chain Monte Carlo	19
3 Prior–Data Fitted Networks	21
3.1 Úvod do Prior–Data Fitted Networks	21
3.2 Praktická motivace k PFN	22
3.3 Vnitřní architektura PFN	23
3.3.1 Fáze 1 - Meta–Learning	24
3.3.2 Fáze 2 - Vstup do modelu	25
3.3.3 Fáze 3 – Transformer vrstvy	27
3.3.4 Fáze 4 – Dekóder, převod embeddingu na logity.	29
3.4 Teoretické statistické vlastnosti PFN	32
3.4.1 Statistický model	32
3.4.2 Od PPD k PFN	34
3.4.3 Učení PFN In–Context	35
3.4.4 PFN transformer	37
4 Experimentální průzkum vlastností PFN	40
4.1 Vnitřní struktura PFN transformeru a jeho základní principy	40
4.1.1 Struktura attention matic	41
4.1.2 Matematický rámec pro srovnávací experimenty	43
4.1.3 Dělá PFN něco podobného jako GP s RBF kernelem?	43
4.1.4 Jak přesný je PFN na skutečné GP realizaci?	46
4.1.5 Konvergence střední hodnoty a kalibrace variance	46
Závěr	49

Úvod

vns. fyffdbeb bdsbf
Text úvodu....

Kapitola 1

Bayesovská statistika

1.1 Základní principy Bayesovské statistiky

Zde bude úvod do hlavních principů a vztahů bayesovské statistiky. Stručně, cca na jednu stránku.

Kapitola 2

Problematika výběru modelů

V této kapitole uvedeme čtenáře do problematiky výběru modelu. Ukážeme si zde jaké různé přístupy výběru modelu při modelování dat existují, jaké potíže se s tím vážou a lze-li tyto potíže elegantně vyřešit. V praxi se často setkáváme se situacemi, kdy musíme pro daná data zvolit nejvhodnější model z několika kandidátů. Například při analýze časových řad můžeme mít několik různých modelů, které by mohly popsat pozorovaná data, a potřebujeme rozhodnout, který konkrétní model z funkčního prostoru je nejvhodnější. Dnes existuje celá řada metod, jak tento konkrétní model určit, jak najít vhodné parametry modelu, ovšem všechny tyto metody jsou zpravidla dost výpočetně náročné. Avšak se to změnilo s příchodem prudkého rozvoje neuronových sítí a hlubokého učení. O Neuronových sítích víme, že to je dobrý aproximační nástroj a ukázalo se totiž, že abychom mohli co nejefektivněji aproximovat hledaný model pro naše data, lze použít architekturu Transformer, která, jak se postupem času dozvíme, je nejpresnější a nejrychlejší řešení tohoto problému. Zavedeme nejdříve obecnou problematiku výběru modelu, poté Bayesovský princip výběru modelu a nakonec si ukážeme, jak nám v tom může pomoci architektura Transformer.

2.1 Obecný princip hledání modelu

V této sekci si ukážeme obecný princip výběru modelu. Představme si následující situaci: máme k dispozici naměřená data, např. z fyzikálního experimentu nebo ze sociální studie a chceme najít model, který tato data co nejlépe popisuje. Tento model může být například lineární nebo nelineární regrese, rozhodovací strom nebo neuronová síť. Dalším účelem modelu je schopnost generalizace na nová, neviděná data, tj. možnost predikce nebo možnost otestovat pravdivost modelu. V tomto okamžiku před námi stojí několik otázek:

- Jakou strukturu modelu musíme zvolit (např. lineární vs. polynomiální)
- Jak správně zvolit hodnoty parametrů a hyperparametrů modelu (např. síla regularizace nebo počet vrstev v neuronové síti)
- Jak moc složitý model zvolit, aby dobře fitoval trénovací data, ale zároveň dobře generalizoval na nová data

Nakonec z toho vyplývá i formulace daného problému: proces výběru modelu je proces systematického výběru optimálního modelu. Během tohoto procesu vzniká i základní trade-off dilema. Zvolíme-li příliš jednoduchý model, nebude schopen zachytit strukturu dat a bude mít špatný fit i špatnou generalizaci (underfitting). Naopak zvolíme-li příliš složitý model, bude perfektně fitovat (interpolovat) trénovací

data, ale bude špatně generalizovat na nová data (overfitting). Cílem je najít optimální model z těchto hledisek.

Dnes existuje celá řada přístupů k výběru modelu. Jsou to tři hlavní přístupy: Bayesovský přístup (marginal likelihood), cross-validace a informační kritéria (AIC, BIC). Cross-validace je praktický a intuitivní přístup, který odhaduje generalizační chybu pomocí validačních dat. Jinými slovy, data rozdělíme na několik částí, pro každou část trénujeme model na ostatních datech a testujeme na ní. Nakonec průměrujeme chyby přes všechny části a vybereme model s tzv. nejnižší cross-validační chybou [Rasmussen]. Dalším velmi populárním přístupem je Bayesovský přístup, který spočívá v tom, že spočítáme pravděpodobnost modelu daná daty. To znamená, že spočítáme tzv. marginal likelihood, což je pravděpodobnost dat daná modelem, integrovaná přes všechny možné hodnoty parametrů modelu. Tento přístup má výhodu v tom, že automaticky penalizuje složité modely a nabízí principiální způsob, jak balancovat fit a složitost modelu. Posledním přístupem jsou informační kritéria, jako je Akaike Information Criterion (AIC) a Bayesian Information Criterion (BIC). Tyto metody poskytují rychlou a jednoduchou aproximaci marginal likelihood, která penalizuje složitost modelu. Nás avšak bude v této práci nejvíce zajímat Bayesovský přístup, protože nám poskytuje nejvíce principů pro výběr modelu a je základem pro náš další postup.

2.2 Bayesův přístup k výběru modelu

Zde ukážeme **Bayesův** princip při výběru modelu. Je zvykem použít hierarchický princip při zavádění Bayesovského výběru modelu [Rasmussen].

Označme tedy $\mathbf{w} \in \mathcal{W}$ jako parametry modelu, kde $\mathcal{W}$ je prostor parametrů modelu, mohou to být např. váhy v lineární regresi nebo v neuronové síti. Dále nechť $\theta \in \Theta$ jsou hyperparametry modelu, kde Θ je prostor hyperparametrů modelu, např. počet vrstev v neuronové síti. Nakonec označme $\mathcal{H}_i \in \mathcal{H}$ jako různé struktury modelu, kde $\mathcal{H}$ je prostor modelů, např. různé architektury neuronových sítí. V Bayesovském přístupu k výběru modelu používáme tzv. Bayesovskou inferenci k odhadu pravděpodobnostního rozdělení parametrů, hyperparametrů a modelů na základě pozorovaných dat $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$, kde $\mathbf{x}_i$ jsou vstupní data a y_i jsou odpovídající cílové hodnoty, anebo alternativně lze označit jako $\mathcal{D} = \{(\mathbf{X}, \mathbf{y})\}$. Tj. cílem je na základě pozorovaných dat dojít k závěru, který model s kterými parametry a hyperparametry nejlépe vysvětluje pozorovaná data.

Na první úrovni hierarchie odhadneme pravděpodobnostní rozdělení parametrů modelu $\mathbf{w}$ pro dané (fixní) hyperparametry θ a model $\mathcal{H}_i$. Zde používáme pojem posteriorního rozdělení, tj. ptáme se, jaké je pravděpodobnostní rozdělení parametrů modelu $\mathbf{w}$ vzhledem k pozorovaným datům $\mathbf{X}$, fixním hyperparametrům θ a modelu $\mathcal{H}_i$. Předpokládejme, že chceme získat predikci pro vstupní data $\mathbf{y}$. Potom podle Bayesovy věty platí:

$$P(\mathbf{w}|\mathbf{y}, \mathbf{X}, \theta, \mathcal{H}_i) = \frac{P(\mathbf{y}|\mathbf{w}, \mathbf{X}, \theta, \mathcal{H}_i)P(\mathbf{w}|\theta, \mathcal{H}_i)}{P(\mathbf{y}|\mathbf{X}, \theta, \mathcal{H}_i)}, \quad (2.1)$$

kde $P(\mathbf{y}|\mathbf{w}, \mathbf{X}, \theta, \mathcal{H}_i)$ je pravděpodobnost **výstupních dat $\mathbf{y}$ podmíněná vstupními daty $\mathbf{X}$** , parametrům modelu $\mathbf{w}$, hyperparametrům θ a modelu $\mathcal{H}_i$ (tzv. likelihood), $P(\mathbf{w}|\theta, \mathcal{H}_i)$ je apriorní rozdělení parametrů modelu $\mathbf{w}$ vzhledem k hyperparametrům θ a modelu $\mathcal{H}_i$, a $P(\mathbf{y}|\mathbf{X}, \theta, \mathcal{H}_i)$ je tzv. evidence dat.

Na druhé úrovni hierarchie odhadneme pravděpodobnostní rozdělení hyperparametrů modelu θ pro daný (fixní) model $\mathcal{H}_i$. Podobně jako na první úrovni používáme Bayesovu větu:

$$P(\theta|\mathbf{y}, \mathbf{X}, \mathcal{H}_i) = \frac{P(\mathbf{y}|\mathbf{X}, \theta, \mathcal{H}_i)P(\theta|\mathcal{H}_i)}{P(\mathbf{y}|\mathbf{X}, \mathcal{H}_i)}, \quad (2.2)$$

kde $P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)$ je pravděpodobnost dat vzhledem k vstupním datům $\mathbf{y}$, hyperparametrům $\boldsymbol{\theta}$ a modelu $\mathcal{H}_i$ (tzv. likelihood), $P(\boldsymbol{\theta}|\mathcal{H}_i)$ je apriorní rozdělení hyperparametrů modelu $\boldsymbol{\theta}$ vzhledem k modelu $\mathcal{H}_i$, a $P(\mathbf{y}|\mathbf{X}, \mathcal{H}_i)$ je evidence dat.

Na třetí úrovni hierarchie odhadneme pravděpodobnostní rozdělení modelů $\mathcal{H}_i$. Opět používáme Bayesovu větu:

$$P(\mathcal{H}_i|\mathbf{y}, \mathbf{X}) = \frac{P(\mathbf{y}|\mathbf{X}, \mathcal{H}_i)P(\mathcal{H}_i)}{P(\mathbf{y}|\mathbf{X})}, \quad (2.3)$$

kde $P(\mathbf{y}|\mathbf{X}, \mathcal{H}_i)$ je pravděpodobnost dat vzhledem k **výstupním hodnotám y podmíněná vstupními daty** $\mathbf{X}$ a modelu $\mathcal{H}_i$ (tzv. marginal likelihood), $P(\mathcal{H}_i)$ je apriorní rozdělení modelů $\mathcal{H}_i$, a $P(\mathbf{y}|\mathbf{X})$ je evidence dat.

Celý tento postup nám umožňuje systematicky vyhodnotit různé modely, jejich hyperparametry a parametry na základě pozorovaných dat a vybrat ten, který nejlépe vysvětluje data podle Bayesovského principu. Zde je dokonce vidět, proč jsme použili hierarchický přístup - na každé úrovni hierarchie odhadujeme pravděpodobnostní rozdělení na základě předchozí úrovně, což nám umožňuje efektivně zachytit nejistotu na různých úrovních modelování. Postupujeme tedy od nejvyšší úrovně nejistoty, což je vůbec výběr modelu, přes střední úroveň, což je výběr hyperparametrů, až k nejnižší úrovni, což je odhad parametrů modelu, tj. se náš problém na každé úrovni zúžuje, tedy jdeme do hloubky nastavení modelu.

Avšak v praxi při výpočtech hustot pravděpodobností na jednotlivých úrovních hierarchie můžeme narazit na problém, že ten integrál neumíme spočítat analyticky, např. protože tato hustota není normalizovaná (neboli tzv. nevlastní). Takovým integrálem je např. normalizační konstanta na první úrovni hierarchie:

$$P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i) = \int_{\mathcal{W}} P(\mathbf{y}|\mathbf{w}, \mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)P(\mathbf{w}|\boldsymbol{\theta}, \mathcal{H}_i)d\mathbf{w}, \quad (2.4)$$

anebo na druhé úrovni hierarchie:

$$P(\mathbf{y}|\mathbf{X}, \mathcal{H}_i) = \int_{\Theta} P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)P(\boldsymbol{\theta}|\mathcal{H}_i)d\boldsymbol{\theta} \quad (2.5)$$

Tyto integrály je nutné aproximovat numericky pomocí takových metod jako Markov chain Monte Carlo (MCMC) nebo pokročilejším No-U-Turn Sampler (NUTS), pokud chceme odhadnou integrál z nenormalizovaných hustot pravděpodobnostní, jako je integrál (2.5), nebo např. Type II maximum likelihood (Type II – MLE), chceme-li odhadnout pouze posteriorní pravděpodobnost pro hyperparametry modelu, což spočívá v Laplaceově aproximaci integrálu (2.4) a následné maximalizaci $P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)$. Všechny tyto metody jsou však dost výpočetně náročné a může trvat značné množství času, než se podaří najít vhodný model pro daná data. Jedním z účelů této práce je ukázat, jak lze tyto pravděpodobnostní hustoty efektivně aproximovat pomocí úplně nového postupu, a to pomocí architektury Transformer.

2.3 GP regrese

Zde si ukážeme, jak aplikovat Bayesovský přístup výběru modelu na konkrétním příkladě, což bude prokládání dat pro nelineární regresi pomocí Gaussovských procesů (dále jen GP). Dále si ukážeme i základní metody pro hledání vhodného modelu, o kterých jsme zmínili v předchozí sekci, a to jsou Type II – MLE a MCMC. Avšak předtím zadefinujeme základní pojmy GP regresi.

Představme si tedy, že máme před sebou následující problém. Někdo nám donesl sadu dat, mohou to být biomedicínská data, data z ekonomických trhu nebo dokonce i data z fyzikálního experimentu a chce po nás sestavit model, který by popisoval tato data a pomocí kterého bychom mohli také stanovit závěry nebo predikce pro budoucí výsledky na základě aktuálních. Je zcela přirozené, že chceme najít

co nejpřesnější model, který by tato data popisoval. Jedním z přístupů, jak toho dosáhnout, je použití Gaussovských procesů (GP) pro regresi. Nejdříve ve zkratce zavedeme pojem GP regresi.

Zvykem je definovat Gaussovský proces pomocí vícerozměrného normálního rozdělení. Mějme tedy vícerozměrnou náhodnou veličinu $\mathbf{X} = (X_1, \dots, X_n)$ a necht' $X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ pro $\forall i = 1 \dots n$, pak říkáme, že $\mathbf{X}$ má vícerozměrné normální rozdělení s vektorem středních hodnot $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)$ a kovarianční maticí Σ , pokud její hustota pravděpodobnosti je dána vztahem:

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right), \quad (2.6)$$

kde $|\Sigma|$ je determinant matice Σ , vektor $\mathbf{x}$ je vektor **realizací**, značíme $\mathbf{X} \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$.

Z toho vztahu plyne i definice Gaussovského procesu [Rasmussen]:

Definice 2.1 (Gaussovský proces). Gaussovský proces je soubor náhodných veličin, libovolný konečný počet kterých má sdružené normální rozdělení.

Dalším klíčovým pojmem je tzv. kovarianční funkce (nebo jádro), která určuje vlastnosti GP. Ta se definuje jako funkce $k : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$, která pro každé dva vstupy $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^d$ vrací hodnotu $k(\mathbf{x}, \mathbf{x}')$, která udává míru podobnosti mezi těmito dvěma vstupy. Je to jistá modifikace kovarianční matice, která je částí klasického vícerozměrného normálního rozdělení, a které vznikne po aplikaci tzv. Kernel triku. Máme-li nějaký proces $f(\mathbf{x})$, teď stejný proces chceme zkoumat i pro jiný vstup, tj. nás zajímá $f(\mathbf{x}')$. Ted' je před námi otázka, jaká je kovariance mezi $f(\mathbf{x})$ a $f(\mathbf{x}')$? Potom se skrz funkční prostor vah a kovarianční matice Σ ukáže, že kovarianční funkce je definovaná jako:

$$k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \Sigma \phi(\mathbf{x}'), \quad (2.7)$$

kde $\phi(\mathbf{x})^T \Sigma \phi(\mathbf{x}')$ je součin v prostoru vah s kovarianční maticí dvou různých vstupů.

Nakonec platí, že Gaussovský proces je plně definován svou střední funkcí $m(\mathbf{x})$ a kovarianční funkcí $k(\mathbf{x}, \mathbf{x}')$. Střední funkci a kovarianční funkci tohoto procesu definujeme jako:

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})], \quad k(\mathbf{x}, \mathbf{x}') = \mathbb{E}[(f(\mathbf{x}) - m(\mathbf{x}))(f(\mathbf{x}') - m(\mathbf{x}'))], \quad (2.8)$$

a následně říkáme, že proces $f(\mathbf{x})$ je Gaussovský proces a značíme $f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$.

Platí dále, že kovarianční funkce, které se také říká kernel (jádro), může mít různé formy. Mezi nejčastěji používané patří např. Radial Basis Function (RBF) kernel (někdy squared exponential kernel), který je definován jako:

$$k(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2l^2}\right), \quad (2.9)$$

kde σ_f^2 je rozptyl funkce a l je délka škály. Pak existuje spousta dalších kernelů, jako je Matérn kernel, Periodic kernel nebo Linear kernel, každý s různými vlastnostmi a aplikacemi, ale pro naše účely postačí základní RBF kernel. RBF kernel má řadu výhod: je hladký, nekonečně diferencovatelný a má tendenci dobře aproximovat širokou škálu funkcí. Současně platí, že každý datový bod můžeme představit jako střed Gaussovského rozdělení. Z předchozí myšlenky plyne i velmi intuitivní myšlenka o tom, jak funguje GP regrese: každý datový bod přispívá k predikci nového bodu podle své vzdálenosti od něj, přičemž váha tohoto příspěvu je určena kovarianční funkcí (jádro). Tím pádem, čím blíže je nějaký bod k jinému bodu, tím větší vliv na něj má: body blízko sebe mají hodnotu blízkou 1, vzdálené body mají hodnotu blízkou 0 a funguje to jako "měřítko podobnosti" mezi body. Pokud bychom tedy chtěli predikovat např. počasí, tak je jasno, že pokud před 5 hodinami bylo -6 stupňů Celsia, před dvěma hodinami -4 stupňů Celsia a před hodinou -5 stupňů Celsia, tak je zjevné, že tyto hodnoty budou mít vliv na predikci počasí za hodinu a ta teplota bude někde mezi -6 a -4 stupňů Celsia a určitě nestoupne nebo neklesne o víc než 5 hodnot.

2.4 Výběr modelu pro GP regresi

V předchozí kapitole jsme si avšak ukázali, že hledat matematické modely, které přesně popisují data, není vůbec jednoduché nebo dokonce nemožné a je potřeba použít různé metody při hledání vhodného modelu. Hlavní potíží je výpočet integrálů, které se objevovaly při sestavování Bayesovské hierarchie. Zde si ukážeme tři přístupy: nejprve obecný rámec variační inference, poté Type II – MLE jako jeho speciální případ a nakonec MCMC jako alternativní metodu.

2.4.1 Variační inference

Variační inference (také Variační Bayes) je obecný přístup k aproximaci těžce vypočítatelných posteriorních rozdělání, které jsme uvedli v předchozí sekci. Místo přímého výpočtu posteriorního rozdělání $P(\mathbf{w}|\mathbf{y}, \mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)$, který dle (2.4) vyžaduje integraci přes celý prostor parametrů, hledáme jeho aproximaci z vhodné parametrické rodiny rozdělání.

Konkrétně zavádíme variační rozdělání $q(\mathbf{w})$ z rodiny $\mathcal{Q}$ (typicky např. normálních rozdělání se strukturovanou kovarianční maticí) a snažíme se ho co nejvíce přiblížit skutečnému posteriornímu rozdělání minimalizací KL divergence:

$$q^*(\mathbf{w}) = \arg \min_{q \in \mathcal{Q}} \text{KL}(q(\mathbf{w}) \| P(\mathbf{w}|\mathbf{y}, \mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)). \quad (2.10)$$

Avšak přímá minimalizace KL divergence je opět náročná pro výpočet, neboť vyžaduje znalost normalizační konstanty (2.4). Namísto toho se maximalizuje tzv. *Evidence Lower BOund* (ELBO):

$$\mathcal{L}(q, \boldsymbol{\theta}) = \mathbb{E}_{q(\mathbf{w})}[\log P(\mathbf{y}|\mathbf{w}, \mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)] - \text{KL}(q(\mathbf{w}) \| P(\mathbf{w}|\boldsymbol{\theta}, \mathcal{H}_i)). \quad (2.11)$$

Lze totiž ukázat, že:

$$\log P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i) = \mathcal{L}(q, \boldsymbol{\theta}) + \text{KL}(q(\mathbf{w}) \| P(\mathbf{w}|\mathbf{y}, \mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i)) \geq \mathcal{L}(q, \boldsymbol{\theta}), \quad (2.12)$$

kde nerovnost plyne z nezápornosti KL divergence. ELBO tedy tvoří dolní mez log-evidence a maximalizace $\mathcal{L}(q, \boldsymbol{\theta})$ přes q odpovídá minimalizaci KL divergence od skutečného posteriorního rozdělání — přičemž normalizační konstantu znát už nepotřebujeme.

Nevýhoda variační inference spočívá v tom, že výsledná aproximace je omezena volbou rodiny $\mathcal{Q}$. Příliš úzká rodina nemusí skutečné posteriorní rozdělání dobře zachytit.

2.4.2 Type II – MLE

Pokud bychom chtěli rychlejší a jednodušší řešení, a namísto hledání celé distribuce nám stačí pouze bodový MLE odhad parametrů, použijeme tzv. Type II maximum likelihood (Type II – MLE), což je speciálním případem variační inference. Tato metoda spočívá v tom, že maximalizujeme tzv. marginal likelihood, což je pravděpodobnost dat daná modelem, integrovaná přes všechny možné hodnoty parametrů modelu. V případě GP regrese je marginal likelihood dána vztahem:

$$P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}) = \int_{\mathcal{W}} P(\mathbf{y}|\mathbf{w}, \mathbf{X}, \boldsymbol{\theta}, \mathcal{H}) P(\mathbf{w}|\boldsymbol{\theta}, \mathcal{H}) d\mathbf{w}, \quad (2.13)$$

kde $\boldsymbol{\theta}$ jsou hyperparametry modelu, $\mathcal{H}$ je struktura modelu, $\mathbf{w}$ jsou parametry modelu, $\mathbf{X}$ jsou vstupní data a $\mathbf{y}$ jsou odpovídající cílové hodnoty. To znamená následující, vzpomeňme si na 2. úroveň hierarchie v Bayesovském přístupu, tj. na rovnici 2.2. Pak posteriorní rozdělání odhadujeme takto:

$$\hat{\boldsymbol{\theta}} = \arg \max_{\boldsymbol{\theta} \in \Theta} P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i) \quad (2.14)$$

Principem tohoto přístupu je, že na základě napozorovaných dat hledáme hyperparametry pro náš model, se kterými on popisuje naše data co nejlépe pro dané modely. Tato metoda ale má řadu nevýhod. Náš odhad totiž skončí v lokálním maximu a nemusí vždy dosáhnout optimálních hodnot. To samozřejmě vynucuje nás zkoušet různé startovní body, zkoumat citlivost odhadu a patrně ladit parametry hledání. To už nemluvíme o ne úplně jednoduchých výpočtech, které také vyžadují jisté množství výkonu a času.

Ze statistiky víme, že jedním ze způsobů, jak najít ML odhad, je použít logaritmickou transformaci a pak najít maximum této funkce. Ukážeme to na konkrétním příkladě a pro to použijeme již definovaný v kapitole (reference) Gaussovský proces s RBF kernelem. Zkusme tedy rozepsat výraz $\log P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta})$ (člen $\mathcal{H}_i$ můžeme vynechat pro lepší čitelnost). Vzpomeňme si, že při definici Gaussovského procesu jsme použili vícerozměrnou Gaussovskou hustotu 2.6. Zlogaritmujeme tento výraz a obdržíme:

$$\log p(\mathbf{y}) = -\frac{1}{2}\mathbf{y}^\top \Sigma^{-1} \mathbf{y} - \frac{1}{2} \log |\Sigma| - \frac{n}{2} \log 2\pi \quad (2.15)$$

Jediné, co nám tedy zbývá v případě Gaussovského procesu, dosadit za kovarianční matici kernelovou matici $K_y = K(\mathbf{X}, \mathbf{X}) + \sigma_n^2 I$, kde $K(\mathbf{X}, \mathbf{X})_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ a σ_n^2 je rozptyl šumu, čímž obdržíme:

$$\log P(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}, \mathcal{H}_i) = -\frac{1}{2}\mathbf{y}^\top K_y^{-1} \mathbf{y} - \frac{1}{2} \log |K_y| - \frac{n}{2} \log 2\pi \quad (2.16)$$

Chceme-li najít extrém této funkce, musíme tento výraz derivovat podle hyperparametrů, čímž dostáváme:

$$\begin{aligned} \frac{\partial}{\partial \theta_j} \log p(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}) &= \frac{1}{2}\mathbf{y}^\top K_y^{-1} \frac{\partial K_y}{\partial \theta_j} K_y^{-1} \mathbf{y} - \frac{1}{2} \text{tr} \left(K_y^{-1} \frac{\partial K_y}{\partial \theta_j} \right) \\ &= \frac{1}{2} \text{tr} \left(\left(\boldsymbol{\alpha} \boldsymbol{\alpha}^\top - K_y^{-1} \right) \frac{\partial K_y}{\partial \theta_j} \right), \end{aligned} \quad (2.17)$$

kde $\boldsymbol{\alpha} = K_y^{-1} \mathbf{y}$. Zde je dokonce vidět, proč tento model není optimální z výpočetního hlediska. Je totiž známo, že najít inverzní matici je dost náročná operace. Pro standardní algoritmy platí, že jejich složitost je $O(n^3)$, kde n je velikost matice. V praxi ovšem n nabývá dost velkých hodnot. Avšak lze vyhnout výpočtu přímé inverze, místo toho se může použít např. Choleského rozklad, který **tento** výpočet může usnadnit. Máme-li spočítanou inverzi, pak je složitost zbylých výpočtů $O(n^2)$. Další nevýhodou je to, že nemusíme spadnout do globálního optima a skončit v lokálním optimu, což opět vyžaduje větší pozornost.

Type II – MLE obrazky a rozepsat členy toho logaritmu.

2.4.3 Markov Chain Monte Carlo

Další metodou je Markov Chain Monte Carlo (MCMC). Ta je založena na teorii Markovských procesů. Její princip spočívá v tom, že se snažíme náhodným vzorkováním z rozdělení aproximovat integrál, který neumíme vyřešit analyticky. Konkrétně už jsme si říkali, že integrály 2.4 a 2.5 nemusíme umět spočítat kvůli jejich příliš velké dimenze nebo kvůli tomu, že tyto hustoty nemusí být vlastní. A tak místo přímého výpočtu budeme postupně generovat vzorky z těchto rozdělení a postupně zjistíme alespoň hrubou představu o skutečné podobě těchto rozdělení, dokonce můžeme i aproximovat jakékoliv statistiky tohoto rozdělení. Dalším podstatným bodem je to, že MCMC je založeno na tzv. Markovových řetězcích což je posloupnost náhodných veličin, pro kterou platí $p(\theta_{t+1}|\theta_t, \theta_{t-1}, \dots, \theta_0) = p(\theta_{t+1}|\theta_t)$, kde θ_i pro $i \in \{1, \dots, T\}$ značí vzorky generované z MCMC. Klíčovým požadavkem je, aby řetězec:

1. byl ergodický, tj. ireducibilní a aperiodický,

2. měl stacionární rozdělení $\pi(\theta)$.

Pak vzorky konvergují k $\pi(\theta)$ a můžeme použít pro odhady:

$$\lim_{T \rightarrow \infty} \frac{1}{T} \sum_{t=1}^T f(\theta_t) = \mathbb{E}_{\pi}[f(\theta)],$$

kde $f(\cdot)$ je v tomto případě skutečná hustota. Dnes již existuje celá řada různých variant MCMC algoritmů, jsou to např. *Metropolis-Hastings algoritmus*, *Gibbs sampling* nebo modernější *Hamiltonian Monte Carlo*. Avšak není účelem této práce rozebírat všechny tyto metody dopodrobna. Nicméně o jedné metodě toho řekneme trochu víc, a to je varianta *No U-Turn Sampler* využívající princip Hamiltonian Monte Carlo. Tato varianta totiž je velmi užívána a relativně účinná při hledání aposteriorních distribucí. Hamiltonian Monte Carlo řeší problém tím, že využívá gradient aposteriorního rozdělení. Základní myšlenkou je pohyb v parametrickém prostoru.

Tento proces vnímáme jako fyzikální systém:

- θ = poloha částice,
- zavádíme pomocnou momentum proměnnou r (někdy p),
- pohyb řídí Hamiltonovy rovnice s energií:

$$H(\theta, r) = -\log p(\theta|\mathcal{D}) + \frac{1}{2} r^T M^{-1} r,$$

kde první člen je potenciální energie (negativní log-posterior) a druhý je kinetická energie.

Rovněž si musíme uvědomit, že částice má tendenci se pohybovat po hladinách konstantní energie, a proto zkoumá prostor efektivněji než náhodné procházky, které používají předchozí algoritmy!

Algorithm 1 Hamiltonian Monte Carlo

- 1: Vzorkuj náhodný momentum: $r \sim \mathcal{N}(0, M)$
 - 2: Simuluj Hamiltonovy rovnice pomocí leapfrog integrace na L kroků délky ϵ
 - 3: Metropolis accept/reject krok (zachovává přesnou stacionaritu)
-

Hamiltonian Monte Carlo avšak má dva hyperparametry, které je těžké nastavit:

- délka kroku ϵ (step size)
- počet kroků L (trajectory length)

NUTS řeší oba problémy tím, že automaticky volí délky trajektorie. To znamená, že pokračuje v simulaci, dokud trajektorie nezačne dělat tzv. *U-turn*, což znamená, že částice se po trajektorii otočí a začne se vracet zpět směrem k místu, odkud vyšla. Toto U-turn kritérium lze vyjádřit takto: směr pohybu začne být opačný než směr od startovní pozice, matematicky to znamená $(\theta_{\text{forward}} - \theta_{\text{backward}}) \cdot \mathbf{r}_{\text{forward}} < 0$, kde skalární součin vektoru mezi krajními body trajektorie a momentem je záporný, což signalizuje, že se pohybujeme zpět. A tento princip má dobrý smysl, jakmile se částice vrací zpět, už není efektivní pokračovat, znamená to, že jsme plně prozkoumali danou "energetickou hladinu". Další kroky by jen ztrácely výpočetní čas tím, že by procházely oblastí, které už jsme navštívili. NUTS tedy automaticky zastaví simulaci v optimálním bodě, když jsme prozkoumali maximum užitečného prostoru, ale ještě před tím než začneme ztrácet efektivitu návratem zpět.

Kapitola 3

Prior–Data Fitted Networks

V této kapitole uvedeme samotnou architekturu Prior–Data Fitted Networks (dále jenom PFN). Začneme krátkou motivací, kde popíšeme hlavní ideu této Deep Learning architektury. Následně ukážeme mechanismy, které se schovávají uvnitř PFN, jinými slovy, jak PFN postupně zpracovává vstupní hodnoty, a to vše na příkladě Gaussovských procesů.

3.1 Úvod do Prior–Data Fitted Networks

Prior–Data Fitted Networks je Deep Learning (dále jenom DL) architektura, kterou v roce 2022 uvedli Samuel Muller a Noah Hollmann v článku (REFERENCE). Hlavní motivací pro vznik tohoto modelu je snaha posunout techniky Bayesovské statistiky na další úroveň spolu se strmým rozvojem v oblasti strojového učení. PFN je založen na proslulé architektuře transformer, která je viníkem dnešního pokroku všemožných Deep Learning modelu, a o niž víme díky velkým jazykovým modelům, a není to náhoda, existuje totiž jisté spojení mezi těmito architekturami. Ačkoli samotnou architekturu PFN a její technické nuance budeme podrobně diskutovat až v následující sekci, zde jenom uvedeme její základní charakteristiky. PFN je tzv. encoder–only architektura (tj. neobsahuje dekodér blok, ale pouze enkóder blok transformeru), na kterou je pak napojena softmax hlava, pro vyhodnocování výsledků ve tvaru pravděpodobností. Na vstup PFN dostává sekvenci dat. V případě velkých jazykových modelu by se jednalo o slovy nebo věty, umístěné v jistém pořadí. Tady je ta myšlenka shodná, ale namísto slov dostane síť neuspořádanou sekvenci dat, které získáme z prior rozdělení. Právě toto je důležitý intuitivní pojetí, na kterém je založená celá ta architektura. Stejně jako po jazykovém modelu, který dostal sekvenci slov, budeme chtít aby odhadl celkový kontext a jako výsledek např. i následující neznáme slovo, které by mohlo následovat, budeme i po PFN chtít, aby po předložení sekvenci dat, zkusil uchopit celkový trend (neboli kontext) a předpovědět, co by mohlo následovat dále. Což je velmi relevantní, když zpracováváme časové řady a chceme řešit regresní problém, jak tomu je např. během práce s Gaussovskými procesy.

Celý princip fungování této metodiky lze popsat následujícím způsobem. Jak již jsme diskutovali dříve, účelem Bayesovského přístupu ve statistice je využití apriorní znalosti nebo informace o jistém jevu v přírodě. A tento princip se dobře prolíná s obecnou úlohou aproximace funkcí pomocí neuronových sítí, protože při jejich návrhu vždy musíme enkódovat apriorní znalosti o této funkci. To se dělá buď přímo skrz architekturu konkrétního modelu nebo za pomoci různých regularizací. Každopádně je to velmi netriviální úloha, kterou je třeba vždy řešit než začneme řešit kteroukoliv úlohu pomocí DL nástrojů. Jako jedno z možných řešení se nabízí právě tzv. Bayesovská inference, jejíž hlavním předpokladem je, že se jistý jev nebo proces vyskytuje v reálném světě a disponujeme informacemi o jeho chování. Tento předpoklad nám umožňuje definovat následující postup. Uvažujme jev nebo celý proces (to jest prior, pro jednoduchost si pod tím můžeme představit obyčejnou množinu dat), ze kterého mů-

žeme neomezeně vzorkovat simulované datové sady $\mathcal{D}$ reprezentující různé prediktivní úlohy (body). Bez újmy na obecnosti předpokládejme, že tyto datové sady obsahují vstupní příznaky $\mathbf{x} \in \mathbb{R}^d$ a k nim příslušné výstupní třídy $y \in \mathcal{Y}$. Během trénování sítě PFN náhodně vygenerujeme dávku (batch) obsahující K takových datových sad. Pro každou i -tou sadu v dávce ($i \in \{1, \dots, K\}$) provedeme následující kroky:

1. Zvolíme náhodně velikost kontextu N_i .
2. Vygenerovanou datovou sadu rozdělíme na kontextovou (trénovací) část $\mathcal{D}_{train}^{(i)} = (\mathbf{x}_j^{(i)}, y_j^{(i)})_{j=1}^{N_i}$ a testovací část obsahující (pro jednoduchost) jeden testovací vzorek $(\mathbf{x}_{test}^{(i)}, y_{test}^{(i)})$. Tedy předložíme modelu data ve tvaru $D^{(i)} = \mathcal{D}_{train}^{(i)} \cup \{\mathbf{x}_{test}^{(i)}, y_{test}^{(i)}\}$, $\forall i \in K$.

Následně natrénujeme náš model q_θ tak, že mu na vstup předložíme kontextovou sadu společně s testovacím příznakem a učíme ho predikovat správný výstup. K tomu minimalizujeme ztrátovou funkci Negative Log-Likelihood (NLL) přes celou dávku K vzorků ve tvaru:

$$L(\theta) = - \sum_{i=1}^K \log q_\theta(y_{test}^{(i)} | \mathbf{x}_{test}^{(i)}, \mathcal{D}_{train}^{(i)})$$

Optimalizací této funkce (např. pomocí gradientního sestupu) hledáme parametry $\hat{\theta} = \arg \min_\theta L(\theta)$, čímž se síť učí provádět inferenci in-context na základě poskytnutých dat.

Toto schéma nám umožňuje aproximovat aposteriorní prediktivní rozdělení (PPD) pro libovolný problém, pro který jsme schopni definovat apriorní rozdělení (prior) a vzorkovat z něj data. Zde je namístě si ujasnit terminologii. **Aposterioorní rozdělení (Posterior)** popisuje naši nejistotu ohledně samotného generativního modelu p (nebo jeho parametrů) poté, co jsme pozorovali trénovací data $\mathcal{D}_n$. Matematicky se jedná o podmíněné rozdělení modelu vzhledem k těmto datům, které se značí jako $\Pi(p|\mathcal{D}_n)$. **Aposterioorní prediktivní rozdělení (PPD - Posterior Predictive Distribution)** naproti tomu popisuje nejistotu ohledně nových dat, které model dosud neviděl, jako je například predikce testovacího štítku y pro nový vstupní příznak x , na základě již pozorovaných dat $\mathcal{D}_n$. Vypočítá se jako průměr všech možných podmíněných rozdělení $p(y|x)$ vážených jejich aposteriorní pravděpodobností. Matematicky je definováno pomocí integrálu:

$$\pi(y|x, \mathcal{D}_n) = \int p(y|x) d\Pi(p|\mathcal{D}_n).$$

Takže účelem PFN je aproximovat právě PPD.

V praxi to znamená, že model je trénován na široké rodině úloh vygenerovaných z tohoto prioru. Tím se PFN naučí implicitně provádět bayesovskou inferenci nad daným prostorem funkcí.

V případě Gaussovských procesů to vypadá následovně: Jelikož známe přesný tvar rozdělení (např. Gaussovský proces s RBF kernelem), dokážeme z něj nekonečněkrát vzorkovat nová data. Navíc můžeme hyperparametrům RBF kernelu přiřadit vlastní rozdělení (tzv. hierarchický prior), čímž úlohu pro PFN zesložíme. V této chvíli se model musí naučit generalizovat (tj. najít obecné řešení) přes celou rodinu funkcí pro všemožné hodnoty hyperparametrů. Potom stačí takto natrénovanému modelu předložit několik známých bodů (tzv. kontext) a on nám v jediném průchodu sítí vrátí rozdělení, které chceme predikovat a snaží se co nejvíce aproximovat původní funkci.

3.2 Praktická motivace k PFN

Abychom navázali na předchozí kapitolu, kde jsme uvedli dnes již standardní metody pro aproximaci PPD, ukážeme motivační příklady s porovnáním PFN s MCMC metody a variační inferencí.

Muller ve své práci tuto problematiku uvedl a na ní představil světu PFN architekturu (REFERENCE-muller). Hlavní výhodou PFN je dle něj to, že na rozdíl od variační inference nebo metod Monte Carlo, že se učí aproximovat PPD přímo z datových vzorků. Jediným a velmi důležitým předpokladem ale je, abychom mohli rychle a výpočetně levně vzorkovat z apriorního rozdělení. Mezitím MCMC požaduje nenormované posteriorní rozdělení. Musíme umět jeho spočítat likelihood a také mít prior jako hustotu, ne jenom možnost vzorkovat. Pro variační inferenci potřebujeme znát sdruženou distribuci parametru a dat, často tyto distribuce jsou těžce spočitatelné. Navíc často je optimalizace takových řešení výpočetně náročná (výpočet gradientů, ELBO optimalizace) a kvalita závisí na volbě variační rodiny rozdělení. Dalším úskalím je, že pro každý nový dataset je nutné spustit celý proces znovu, což jenom zhoršuje časovou a výpočetní náročnost při řešení jistého problému. Výhodou těchto klasických řešení je, že např. MCMC konverguje k pravému posterioru v limitě nekonečně mnoha vzorků. Type II – MLE (speciální případ variační inference) konverguje k pravým hyperparametrům v limitě nekonečně dat za předpokladu korektně specifikovaného modelu. Navíc pro všechny modely platí, že systematická chyba takových aproximací, tzv. bias, jde k nule.

PFN obrací situaci. Model je předtrénován offline na obrovské mase syntetických datasetů z prioru a inference se pak provádí jediným dopředním průchodem (forward passem) sítí. Strukturální požadavek je výrazně slabší – stačí umět vzorkovat z apriorní distribuce, není potřeba hustota ani její gradient. To otevírá třídu priorů, kterou klasické metody pojmut neumí, např. BNN s libovolnou architekturou nebo ručně psané generativní procedury. Inference je řádově rychlejší, protože model je předtrénovaný. Müller ukazuje cca 200× zrychlení proti type II – MLE a přibližně 1000 × ~8000× proti NUTS, navíc na rozdíl od NUTS, PFN neprovádí žádné optimalizace před inferencí (tj. žádný warmup, žádná adaptace, žádné chain diagnostics). Konečně, PFN není trénován na rekonstrukci posterioru bod po bodu, ale přímo na predikční kvalitě skrz cross-entropy s PPD. Nevýhody jsou strukturální. Jak se ukáže dále, nemáme vždy zaručeno to, že bias bude klesat k nule. Naopak např. u architektury transformer bias nikdy nezmizí. To je kvalitativně jiná situace než u NUTS nebo type II – MLE, které teoreticky konvergují přesně k prioru a jejich bias postupně mizí. Další nevýhodou je např. to, že pokud testovací dataset pochází z jiné distribuce než trénovací prior, PFN může selhat nebo minimálně výsledky nebudou tak přesné. NUTS je oproti tomu robustní v tom smyslu, že jeho výstupem je vždy korektní posterior pro právě ten model, který byl explicitně specifikován, bez ohledu na původ dat. Nakonec je třeba mít na paměti, že PFN musí být předem natrénovaný na konkrétním problému a s obrovským množstvím dat. Např. pokud bychom chtěli aproximovat Gaussovský proces, je třeba PFN předem natrénovat na dostatečně velké rodině funkcí a pestrout distribucí parametrů/hyperparametrů. Pokud by samozřejmě někdo to udělal za nás, a používali bychom předtrénovaný PFN jako hotový produkt (via dnešní LLM), pak bychom pro libovolný problém dostávali okamžitou aproximaci.

3.3 Vnitřní architektura PFN

V této sekci se pokusíme popsat procesy, které se dějí uvnitř PFN transformeru. Naším účelem není poskytnout kompletní popis architektury transformer obecně, za co odpovídají jednotlivé komponenty nebo parametry. Předpokládáme, že čtenář je již seznámen se základy architektury transformer. Pokud tak tomu není, doporučujeme nastudovat alespoň základní pojmy a principy této architektury. Potřebné zájemce jenom odkážeme na příslušnou kapitolu v knize (REFERENCE UNDERSTANDING DEEP LEARNING). Přesto pevně věříme, že našemu výkladu budou rozumět i laici v oblasti strojového učení, neboť zde nepotřebujeme pokročilé znalosti nebo složité pojmy a zkusíme vše popsat co nejjednodušeji. Pokud se takové ve výkladu objeví, slouží jenom pro odborníky v této oblasti a na porozumění hlavních principů nebudou mít velký vliv. Dále opět podotýkáme, že účelem práce není rozebírat konkrétní implementaci PFN a související se s tím nuance. Navíc PFN je relativně mladá architektura, které se neustále

vylepšuje a aktualizuje, proto pro nás nemá smysl jít do takových detailů. Aktuální verzi zdrojového kódu PFN naleznete zde (REFERENCEpfnit).

V předchozí sekci jsme již zmínili, že PFN je transformer, který se trénuje na obrovském množství syntetických datasetů, které vzorkujeme z prioru. Tímto způsobem se PFN naučí provádět Bayesovskou inferenci a po natrénování stačí jeden forward pass sítí a model vrátí kompletní PPD pro nové testovací body na vstupu. V této sekci budeme uvažovat, že naším priorem je Gaussovský proces s RBF kernelem. Dále chceme upozornit, že celý proces, který se odehrává uvnitř PFN od vstupu po výstup, popíšeme s použitím konkrétní konfigurace, kterou jsme běžně používali během zkoumání PFN:

1. Dimenze embeddingu $EMSIZE = 512$.
2. Počet attention hlav v každé vrstvě $NHEAD = 8$.
3. Dimenze vnitřních skrytých vrstev dopředných neuronových sítí $NHID = 1024$.
4. Počet vrstev $NLAYERS = 6$.

Jelikož se vše chystáme navíc ukázat pro případ 1D GP regrese, použijeme úplně klasické nastavení PFN, které uvádějí Muller a Hollmann v (REFERENCEmuller), konkrétně s těmito parametry:

- `features_per_group = 1` — nastaven na jedničku, protože řešíme 1D regresi.
- `attention_between_features = False` — slouží pro zpracování tabulkových dat; pokud je zapnutý, jedná se o architekturu **TabPFN**, kterou v této práci neuvažujeme (viz REFERENCEtabpfn).

Nakonec uvažujme, že provádíme inferenci pro GP regresi s 20 trénovacími a 50 testovacími body. Teď už máme nachystané formální parametry a nastavení, což nám umožňuje se pustit na samotný popis. Celý proces si rozdělíme na několik fází.

3.3.1 Fáze 1 - Meta-Learning

Pro obecnost ukážeme, jak probíhá učení pro případ, kdy hyperparametry pro RBF kernel nejsou známy a pochází z nějakého rozdělení. Případ fixních hyperparametrů je pouze speciálním případem tohoto problému a všechno, co napíšeme dále, platí i pro tento speciální případ. Meta-Learning je paradigma strojového učení, které spočívá v tom, že namísto toho, abychom model naučili řešit jeden konkrétní fixní problém, naučíme ho řešit celou třídu podobných úkolů. Konkrétně v našem případě by to znamenalo, že model naučíme na základě dat z GP s RBF kernelem, kde mu ukážeme celé spektrum všemožných hyperparametrů, které se v RBF kernelu vyskytují. Potom stačí jenom předložit modelu těch 20 kontext bodů a hned bude schopen aproximovat GP, ze kterého tyto body pocházejí. V předchozí sekci jsme již drobně popsali, jak funguje trénink PFN, formálněji a mnohem podrobněji lze tento proces zapsat takto:

Algorithm 2 Meta-trénink sítě PFN na syntetických GP datech

Require: Model q_θ , apriorní rozdělení hyperparametrů Π , velikost kroku η , velikost dávky m

- 1: **while** není dosaženo konvergence **do**
- 2: **for** $j = 1, \dots, m$ **do**
- 3: Vzorkuj hyperparametry GP: $(\ell_j, \sigma_j, \sigma_{n,j}) \sim \Pi$
- 4: Vzorkuj vstupní body $x_1, \dots, x_N$ rovnoměrně z $[0, 1]$
- 5: Vzorkuj výstupy z GP s daným kernelem: $(y_1, \dots, y_N) \sim \mathcal{GP}(0, k_{\ell_j, \sigma_j}) + \mathcal{N}(0, \sigma_{n,j}^2 I)$
- 6: Rozděl na kontextovou sadu $\mathcal{D}_j = \{(x_i, y_i)\}_{i=1}^n$ a testovací body $\{(x_i^*, y_i^*)\}_{i=1}^t$
- 7: **end for**
- 8: Předej q_θ kontexty $\mathcal{D}_j$ a testovací vstupy x_i^* ; model vrátí prediktivní distribuce přes biny
- 9: Spočítej ztrátu (NLL):

$$\mathcal{L}(\theta) = -\frac{1}{m} \sum_{j=1}^m \sum_{i=1}^t \log q_\theta(y_i^* | x_i^*, \mathcal{D}_j)$$

- 10: Aktualizuj: $\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}(\theta)$
 - 11: **end while**
 - 12: **return** $\hat{\theta}$
-

Tímto způsobem se dostáváme do situace, kdy model vidí miliony různých datasetů generovaných z GP prioru a učí se pravidla, dle kterých pak musí uhádnout, jak vypadá posteriorní predikce na základě předložených dat. Tohle je velmi důležitá myšlenka, PFN se neučí aproximovat konkrétní funkce, učí se inferenční pravidlo.

3.3.2 Fáze 2 - Vstup do modelu

Během inference model dostane tři tenzory:

1. Souřadnice trénovacích bodů `x_train`.
2. Naměřené hodnoty na trénovacích bodech `y_train`.
3. Souřadnice testovacích bodů `x_test`.

Jak už plyne z logiky věci, `x_train` a `y_train` jsou dva různé objekty, první říká, kde jsme měřili (souřadnice na ose x), a druhý říká, co jsme v těchto místech naměřili. Tak dohromady tvoří datové body (x_i, y_i) . Souřadnice `x_test` nám říká, kde chceme ty predikce, přitom model by měl vrátit pravděpodobnostní rozdělení pro příslušné y -hodnoty, ale k tomu se dostaneme později v našem výkladu. Následně se `x_train` a `x_test` spojí do jedné sekvenci a model s nimi pracuje jako s jedním objektem. Přičemž modelu současně explicitně řekneme, že prvních 20 souřadnic jsou trénovací hodnoty a zbytek jsou testovací (50 testovacích souřadnic), jak jsme si to definovali na začátku sekce. Pro y -hodnoty je ta situace podobná, vytvoříme jednu sekvenci pro `y_train` a `y_test` hodnoty, až na to, že místo test hodnot vložíme NaN hodnoty, protože právě ty musí model odhadnout a nechceme je do modelu vkládat v žádné podobě. Pro zájemce uvedeme, jak to pak vypadá v kódu. V metodě `forward()` se `x_train` a `x_test` spojí pomocí funkce konkaténace:

```
1 x = torch.cat((x_train, x_test), dim=1) # (1, 70, 1)
```

Jedná se o tenzor, kde první dimenze je počet datasetů, které zpracováváme naraz, druhá dimenze je počet bodů v sekvenci a třetí dimenze je počet příznaků, který jsme na začátku této sekce nastavili na 1. Pro y -hodnoty analogicky:

```
1 y = torch.cat((y_train, NaN * torch.zeros(1, 50, 1)), dim=1) # (1, 70, 1)
```

Zde je explicitně vidět, že test hodnoty se nahradí za NaN. Dále si myslíme, že je namístě říct jedno upřesnění, aby nedošlo k nedorozumění. To, že modelu v y -hodnotách předkládáme NaN neznamená, že pak budeme chtít tyto hodnoty nahradit za odhady někde v průběhu zpracovávání, je to čistě technická záležitost. Zůstanou NaN po celou dobu. Výsledky obdržíme v jiné podobě, opět, budeme o tom diskutovat dále.

Dále následuje tzv. *Feature grouping*, o parametru, který určuje počet příznaku jsme také zmiňovali na začátku sekce. Připomínáme, že pro náš jednoduchý případ 1D regrese je naven na 1. Tento mechanismus slouží hlavně pro případ, kdy chceme zpracovávat tabulkové hodnoty, anebo pracovat s vícerozměrnými daty, ale to se týká hlavně verze modelu **TabPFN**. V tabulkových datech s 12 sloupci (věk, plat, výška, ...) model potřebuje tyto sloupce nějak zpracovat. Parametr `features_per_group` určuje, kolik sloupců se seskupí do jednoho tokenu. Pro náš 1D GP je grouping triviální: máme 1 příznak, tedy 1 grupu. Tensor x se tak přeformátuje z (1, 70, 1) na (1, 70, 1, 1).

Dalším krokem je převod dat na vstupu na tzv. *embedding*, tj. do řeči, které rozumí transformer. Ve skutečnosti se jedná o vytváření nového prostoru, ve kterém pak PFN bude operovat s daty, a kterému rozumí víc, než kdyby musel pracovat pouze se sekvencí dat.

X-encoder:

Zde to je jednoduchá lineární vrstva, která vezme jednu konkrétní číselnou hodnotu x -souřadnice a vynásobí ji maticí vah 1×512 (parametr velikosti embeddingu jsme nastavili nahoře). Výsledkem je 512-dimenzionální vektor (*embedding*). Tímto způsobem jsme zakódovali polohu bodu v tom novém prostoru, ze kterého model umí jednoduše číst a operovat v něm. Výstupem je `embedded_x` tvaru (1, 70, 1, 512)

Y-encoder:

Pro y -hodnoty je ta situace zajímavější, jelikož v předchozím kroku, jsme si řekli, že pro testovací hodnoty modelu předložíme NaN hodnoty. A teď otázkou je, jak tyto hodnoty zakódovat do *embeddingu*. K tomu slouží metoda `NanHandlingEncoderStep`, která nejdříve transformuje skalární y -hodnotu na vektor délky 2:

1. Pro trénovací pozice (y existuje): $[y, -1]$ — skutečná hodnota a indikátor "data jsou k dispozici".
2. Pro testovací pozice ($y = \text{NaN}$): $[0, +1]$ — nulová hodnota a indikátor "data chybí".

Pak lineární vrstva opět převede dvourozměrný vektor do 512-dimenzionálního prostoru. Výstupem je `embedded_y` tvaru (1, 70, 512), tady je o jeden parametr méně, protože příznaky mezi skupinami se nevztahují na y -hodnoty.

V této chvíli máme dva embeddingy, cílem ale je, mít jeden hromadný embedding, který v sobě nese informace o souřadnici x a odpovídající ji hodnotě y . Zde opět existují dva způsoby implementace v PFN: pro `attention_between_features=False` a `attention_between_features=True`, kde poslední verze je opět určena pro práci s vícedimenzionálními daty. Pro tu první verzi je postup velmi jednoduchý – `embedded_x` a `embedded_y` jednoduše sečteme. Výsledkem je jeden token pro jednu konkrétní pozici, tj. tento token kombinuje informaci o poloze x a hodnotě y v jednom vektoru. Sčítání tady funguje, protože oba embeddingy jsou již stejného tvaru a jsou ve stejném 512-dimenzionálním prostoru a model bude umět z tohoto součtu dekodovat obě informační položky díky předchozímu postupu. V kódu to pak formálně vypadá následovně:

```
1 embedded_input = embedded_x + embedded_y.unsqueeze(2)
2 # (1, 70, 1, 512) + (1, 70, 1, 512) -> (1, 70, 1, 512)
```

Druhý režim zde již popisovat nebudeme, zájemce odkážeme na zdrojové kódy na GitHub, které jsme uvedli na začátku kapitoly.

3.3.3 Fáze 3 – Transformer vrstvy

Tenzor `embedded_input` pak musí projít 6 transformer vrstvami (jejich počet jsme též definovali na začátku sekce). Jakmile embeddingy vstupují do transformer vrstev je zvykem jim říkat token. To znamená, že objektům `embedded_x` a `embedded_y` bychom říkali `x_token` a `y_token`. Ačkoliv jsme tyto dva embeddingy sloučili do jednoho, pořád musíme na ně nahlížet jako na samostatné objekty, protože naším cílem je nakonec získat `y_token`, který v sobě bude obsahovat predikce pro testovací hodnoty. Sloučení se tedy provádí pouze pro technické potřeby architektury. Vraťme se ale zpátky k věci. Každá vrstva v naší konfiguraci provádí dvě hlavní operace:

1. Self-attention přes datové body (neplést s attention between features)
2. Feedforward MLP

Self-attention:

Tenzor se transponuje na $(1, 1, 70, 512)$, aby sekvence 70 bodů byla na dimenzi $\text{dim}=2$ (standardní konvence pro attention). Multi-head attention s 8 hlavami pak počítá:

Pro každou hlavu h (z 8):

$$Q^{(h)} = x \cdot W_Q^{(h)}, \quad K^{(h)} = x \cdot W_K^{(h)}, \quad V^{(h)} = x \cdot W_V^{(h)}$$

kde $W_Q, W_K \in \mathbb{R}^{512 \times 64}$ a $W_V \in \mathbb{R}^{512 \times 64}$ (protože $512/8 = 64$).

Klíčový detail: K a V se počítají pouze z trénovacích bodů. V kódu:

```
1 attention_src_x = x[:, :single_eval_pos].transpose(1, 2)
2 # first 20 positions
```

Attention matice je pak:

$$A = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{64}}\right)$$

Pro trénovací body (pozice 0–19) je Q i K ze stejných 20 bodů, takže matice je 20×20 — trénovací body se dívají na sebe navzájem.

Pro testovací body (pozice 20–69) Q pochází z testovacích bodů, ale K pochází z trénovacích bodů. Matice je 50×20 — testovací body se dívají na trénovací body.

Tohle je přímá analogie ke GP predikci. Ve formuli $\mu_* = k(x_*, X)K^{-1}y$ se testovací body taky „dívají“ na trénovací body přes kernel $k(x_*, X)$. Rozdíl je, že GP používá explicitní RBF kernel, zatímco PFN se naučil vlastní implicitní „kernel“ zakódovaný ve váhách W_Q a W_K .

Výstup attention:

$$\text{Output}^{(h)} = A \cdot V^{(h)}$$

Všech 8 výstupů (každý $\in \mathbb{R}^{64}$) se zřetězí a projde výstupní projekcí W_O :

$$\text{MultiHead} = \text{Concat}(\text{Output}^{(1)}, \dots, \text{Output}^{(8)}) \cdot W_O$$

Po attention následuje reziduální spojení (vstup + výstup attention) a LayerNorm — normalizace, která stabilizuje trénink. Reziduální spojení je technika, která přidává původní vstupní reprezentaci (třeba embedding datového bodu) k výstupu nelineární vrstvy (například MLP) těsně předtím, než tento výsledek pošle dál do sítě. Reziduální spojení zajišťuje, že model nezačíná optimalizaci chaotickým hádáním,

nýbrž bezpečným průtokem dat, ke kterému postupně přidává potřebnou komplexitu. Co se týče Layer-Norm, ten normalizuje embedding na nulový průměr a jednotkový rozptyl přes posledních d dimenzí (v našem případě 512). Pro vektor x délky 512:

$$\text{LayerNorm}(x) = \frac{x - \mu}{\sigma + \epsilon},$$

kde μ a σ jsou průměr a směrodatná odchylka přes 512 komponent vektoru a $\epsilon = 10^{-5}$ je malá konstanta pro numerickou stabilitu.

MLP – Multi-Layer Perceptron:

MLP je dvouvrstvá dopředná síť:

vstup (512) $\rightarrow$ Linear(512 $\rightarrow$ 1024) $\rightarrow$ GELU $\rightarrow$ Linear(1024 $\rightarrow$ 512) $\rightarrow$ výstup (512)

Vezme 512-dimenzionální vektor, rozšíří ho do 1024 dimenzí přes lineární vrstvu, aplikuje nelineární aktivaci GELU (hladká varianta ReLU), a zase zúží zpět na 512.

GELU (Gaussian Error Linear Unit) je funkce

$$\text{GELU}(x) = x \cdot \Phi(x),$$

kde Φ je distribuční funkce standardního normálního rozdělení. Pro velká kladná x se chová jako identita, pro velká záporná x vrací přibližně nulu.

Proč nakonec musíme přidávat MLP je pro zkušeného čtenáře v oblasti strojového učení poněkud triviální otázka, vysvětlíme i pro ostatní čtenáře. Attention je totiž lineární operace (ačkoliv se to nezdá), počítá pouze vážené průměry. MLP do tohoto procesu přidává nelinearitu, bez něj by transformer mohl dělat jenom lineární transformace s embeddingy. Avšak ve strojovém učení je to nedostačující, chceme zachytit a složitější transformace a operace, čímž zvyšujeme generalizační schopnosti modelu. A právě díky této vlastnosti může PFN aproximovat např. inverzi matice $\mathbf{K}^{-1}$ v GP. Váhy druhé lineární vrstvy jsou inicializovány na nulu. To znamená, že na začátku tréninku MLP vrací nulový vektor, a tak se tato vrstva na začátku chová jako identita. To se však mění v průběhu tréninku. Model začíná od jednoduchého stavu a postupně se učí komplexnější transformace. Po MLP opět následuje reziduální spojení a normalizace.

Toto se opakuje tolik, kolik vrstev obsahuje model, v našem případě 6 krát. Po každé vrstvě se embedding každého bodu obohacuje o informaci z ostatních bodů (přes attention) a transformuje (přes MLP). Po 6 vrstvách embedding testovacího bodu obsahuje dostatečnou informaci k tomu, aby dekóder z něj vyrobil prediktivní distribuci.

Po průchodu 6 vrstvami dostáváme opět nový tenzor. Ten obsahuje zpracované reprezentace jak trénovacích, tak i testovacích bodů. Naším úkolem teď by bylo extrahovat testovací hodnoty y (neboli y -tokeny, jak jsme diskutovali výše), respektive jejich predikce, které model postupně vyrobil. Zbytek je pro účely inference nepodstatný. Platí totiž, že celá architektura PFN je postavena tak, že se právě v y -tokenu postupně akumulují informace přes všechny vrstvy transformeru přes attention z x -tokenů a z kontextu trénovacích bodů. Na konci celého procesu y -token pro testovací pozici obsahuje 512-dimenzionální vektor, který implicitně kóduje celou posteriorní prediktivní distribuci (PPD) pro daný trénovací bod. Uveďme opět pro zájemce, jak tento proces vypadá uvnitř, což by mělo pomoci k pochopení, co se v tomto kroku odehrálo:

```
1 # Split into train and test part
2 test_encoder_out = encoder_out[:, current_context_len:, :]
3 # (1, 50, 1, 512) -- test positions (20-69)
4
5 train_encoder_out = encoder_out[:, :current_context_len, :]
6 # (1, 20, 1, 512) -- train positions (0-19)
```

Proměnná `current_context_len` je rovna `single_eval_pos = 20`.

V dalším kroku se extrahuje *y*-token — poslední token v dimenzi *feature groups*:

```
1 test_encoder_out = test_encoder_out[:, :, -1, :]  
2 # (1, 50, 512) -- only y-token for test positions
```

3.3.4 Fáze 4 – Dekóder, převod embeddingu na logity.

Jsme si již řekli, že PFN je encoder-only architektura, tj. decoder blok, který je součástí obecné architektury transformer, v něm chybí. Decoder blok ale je napojen na hlavu, která v sobě obsahuje opět MLP vrstvu a softmax vrstvu. Tyto součástky však budeme potřebovat. Na konci předchozí fáze jsme získali tenzor `test_encoder_out` o tvaru (1, 50, 512), který v sobě obsahuje pro každý z 50 testovacích bodů jeden 512-dimenzionální embedding. Ted' potřebujeme z tohoto vektoru vytvořit prediktivní distribuci. To se opět udělá pomocí MLP (jednoduchá dopředná síť), která je doplněná o jednu novinku. Celkově schéma vypadá následovně:

vstup (512) → Linear(512 → 1024) → GELU → Linear(1024 → numBars) → výstup (numBars)

Jednotlivé prvky v schématu, který jsme uvedli na začátku sekce, plní následující funkci:

1. **Linear(512 → 1024)**: Vezme 512-dimenzionální embedding a promítne ho do 1024 dimenzí. To je lineární transformace — násobení maticí vah $W_1 \in \mathbb{R}^{512 \times 1024}$.
2. **GELU()**: Aplikuje nelineární aktivaci. Bez ní by dvě lineární vrstvy za sebou byly ekvivalentní jedné lineární vrstvě (součin matic je matice). GELU umožňuje decoderu zachytit nelineární vztahy mezi embeddingem a výstupní distribucí.
3. **Linear(1024 → numBars)**: Zúží z 1024 dimenzí na numBars (řekněme 1000). Výstupem je 1000 čísel — **logity** — jedno pro každý bucket.

Je vidět, že tady se objevuje nová proměnná `numBars`, jedná se totiž o analogii binu v histogramech, který se zavádí pro tzv. **BarDistribution**.

BarDistribution

BarDistribution je po-částech konstantní pravděpodobnostní rozdělení. V článku (REFERENCE-muller) se mu říká *Riemann distribution*, jedná se o diskretizaci spojité distribuce. Vizualně to vypadá takto: Avšak je důležité odlišit tento koncept od klasického histogramu. Histogram odhaduje hustotu z dat. Hlavním principem je, že počítáme klik naměřených hodnot padlo do každého binu, a to určuje výšku jednotlivých sloupců. BarDistribution je naopak výstup modelu, tj. my neděláme měření a nepočítáme, kolik hodnot padlo do toho či oného binu. Právě samotný model určuje výšku sloupců dle nějakých svých pravidel. Neuronová síť na výstupu vrátí *n* čísel, každé číslo říká, jak vysoký má být jeden sloupec. To jest distribuce určuje síť, to umožňuje pak modelovat pestrou škálu různých rozdělení a nejsme omezení jenom normálním, exponenciálním rozdělením apod. Binům se v BarDistribution říká *bucket*. V implementaci je BarDistribution definován pomocí hranic (parametr `borders`), tím definujeme interval, na kterém je tato funkce definována. Může to vypadat například takto:

`borders = [-3.0, -2.994, -2.988, ..., 0.0, ..., 2.988, 2.994, 3.0]` Mezi sousedními hranicemi leží jeden bucket. Bucket č. *i* pokrývá interval $[b_i, b_{i+1})$ a má šířku $w_i = b_{i+1} - b_i$. V naší konfiguraci jsou `borders` typicky rovnoměrně rozložené, takže všechny buckety mají stejnou šířku. Implementace ale podporuje i nerovnoměrné dělení (hustší buckety v zajímavých oblastech, řidší na krajích).

Vraťme se zpátky k dekodování. Jednotlivé prvky v schématu, který jsme uvedli na začátku sekce, plní následující funkci:

1. `Linear(512 -> 1024)`: Vezme 512-dimenzionální embedding a promítne ho do 1024 dimenzí. To je lineární transformace — násobení maticí vah $W_1 \in \mathbb{R}^{512 \times 1024}$.
2. `GELU()`: Aplikuje nelineární aktivaci. Bez ní by dvě lineární vrstvy za sebou byly ekvivalentní jedné lineární vrstvě (součin matic je matice). GELU umožňuje decoderu zachytit nelineární vztahy mezi embeddingem a výstupní distribucí.
3. `Linear(1024 -> numBars)`: Zúží z 1024 dimenzí na `numBars` (řekněme 1000). Výstupem je 1000 čísel, říkáme jim **logity**, jeden pro každý bucket.

Logit v tomto případě je jenom surové číslo z poslední lineární vrstvy našeho dekodéru. Může to být jakékoliv reálné číslo. Důležité ale je, že nemají žádné jednotky, nesčítají se na jedničku a ne této etapě nemají žádnou přímou pravděpodobnostní interpretaci. Logit je pouze signál pro určitý bucket, do kterého spadne, jak moc si model myslí, že skutečná hodnota padne do daného intervalu. Čím vyšší je logit, tím více si je model jistý. Ale pro lepší interpretovatelnost musí tyto hodnoty nejdříve projít softmax vrstvou. Uvažujeme-li, že máme 1000 bucketů, softmax převede 1000 logitů na 1000 pravděpodobností:

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^{1000} e^{z_j}}$$

Logicky pak součet všech pravděpodobností je přesně 1 a vyšší logit implikuje vyšší pravděpodobnost. Hustotu pravděpodobnosti potom definujeme jako $f_i = \frac{p_i}{w_i}$, kde w_i je šířka bucketu. Širší bucket musí mít nižší hustotu při stejné pravděpodobnosti, aby distribuce dávala smysl jako aproximace spojitého rozdělení. Při rovnoměrných bucketech je tento rozdíl jen konstantní škálování. Evidentně pak můžeme dopočítat i všechny potřebné deskriptivní charakteristiky jako střenění hodnotu, rozptyl atd. Jak jsme již minili dříve, neklademe na `BarDistribution` žádná omezení co se týče tvaru výsledné distribuce. Avšak v kontextu GP inference výstup typicky vypadá přibližně jako gaussovský zvon. To proto, že GP posteriorní prediktivní distribuce je přesně normální rozdělení. Pokud PFN dobře aproximuje GP posterior, buckety budou mít tvar zvonu. Ale model to nikdo nenutí, naučil se to sám, protože loss funkce, se kterou byl model trénován, ho odměňuje za to, že jeho distribuce co nejlépe odpovídá skutečné posteriorní distribuci.

Dále poskytneme krátký komentář, proč během trénování PFN volíme pro loss funkci právě Negative Log-Likelihood (NLL) tvar. NLL je ztrátová funkce, která měří kvalitu predikované distribuce. Postupuje následovně:

1. Model vyprodukuje logity $z_1, \dots, z_{1000}$.
2. Softmax je převede na pravděpodobnosti $p_1, \dots, p_{1000}$.
3. Pravděpodobnosti se převedou na hustoty: $f_i = p_i/w_i$.
4. Najde se bucket k , do kterého padne skutečné y_{test} .
5. Loss pro tento bod je: $\mathcal{L} = -\log(f_k) = -\log(p_k) + \log(w_k)$

Člen $\log(w_k)$ je konstanta (borders se nemění), takže gradient teče jen přes $-\log(p_k)$. Minimalizace NLL je ekvivalentní maximalizaci likelihood, to znamená, že model se učí přiřadit co nejvyšší hustotu tam, kde skutečné y leží.

Otázkou je, proč bychom nemohli volit např. tvar Mean Square Error (MSE) jako loss funkci. MSE loss by měřil jen $(y_{\text{pred}} - y_{\text{true}})^2$, tj. chybu bodového odhadu. NLL přes `BarDistribution` měří kvalitu celé distribuce. Model se učí nejen správný střed, ale i správnou šířku a tvar nejistoty. To je přesně

to, co potřebujeme pro aproximaci GP posterioru, chceme celou PPD, ne pouze průměr. Navíc, jak se ukáže dále (REFERENCEnagler), minimalizace NLL vede k optimálnímu řešení, které je Bayesovská posteriorní prediktivní distribuce, tedy přesně to, co GP analyticky počítá.

Na konci sekce zkusíme shrnout kompletní postup. Na úplném začátku jsme modelu předložili sadu trénovacích a testovacích bodů, přitom ale model nedostal `y_test` a účelem bylo ho naučit tyto hodnoty predikovat. PFN postupně zpracovalo a přetransformovalo skrz svoje vrstvy `x_train`, `y_train` a `x_test`. To znamená, že model zpracoval mu předložená informace jako celek naraz. Během toho se PFN naučilo pravidlo, jak se chovají různé GP posteriory pro různé parametry. Na konci jsme dostali pravděpodobnostní rozdělení pomocí převodu na logity a použití `BarDistribution`. Výsledek jsme vždy porovnali se skutečným GP a jako metriku, jak moc dobře PFN odhaduje skutečnost, jsme použili NLL, který bychom chtěli minimalizovat. Po dostatečném tréninku jsme pak dostali model, který na základě předložených dat ze skutečného GP prioru, které nikdy neviděl, je schopen odhadnout, odkud pochází a jak vypadá funkce, ze které pochází.

3.4 Teoretické statistické vlastnosti PFN

V této sekci uvedeme dosud známé statistické vlastnosti PFN, které publikoval Nagler v článku (REFERENCE nagler). V okamžiku, kdy již máme natrénovaný model, dává smysl prozkoumat jeho statistické vlastnosti a ptát se, proč a jak fungují jeho prediktivní a aproximační schopnosti. Muller ve své práci ukázal empirická pozorování, která ale nepodpořil teoretickým zdůvodněním. To se avšak podařilo Naglerovi, který dokázal vybudovat teoretický základ pro PFN a řádně odůvodnit, proč a jak architektura PFN dává dobré výsledky při Bayesovské inference. Nagler ve své práci používá určitý formalismus pro zavedení celého problému, na kterém pak buduje samotnou teorii. My tento formalismus v této práci zachováme.

3.4.1 Statistický model

Uvažujme klasifikační úlohu, která se skládá ze tříd $Y \in \mathcal{Y}$ a příznaků $X \in \mathcal{X} \subseteq \mathbb{R}^d$. Předpokládejme dále, že máme iid data $D_n = (Y_i, X_i)_{i=1}^n$ pocházející z nějakého teoretického, avšak neznámého rozdělení p_0 . Naším cílem je predikovat toto podmíněné rozdělení na základě dostupných dat:

$$p_0(y | x) = P(Y = y | X = x).$$

Z hlediska Baysevského neparametrického odhadování můžeme na p_0 nahlížet jako na realizaci náhodného parametru $p \in \mathcal{P}$, kde $\mathcal{P}$ je prostor podmíněných pravděpodobnostních rozdělení nad $\mathcal{Y} \times \mathcal{X}$. Tento parametr má rozdělení Π , které budeme říkat prior. Prior bude vyjadřovat naše přesvědčení o tom, jaké modely p jsou pravděpodobnější pro daný problém ještě předtím než uvidíme data. Formálně celý proces, ze kterého pocházejí data lze zapsat takto:

1. Vygeneruj $p \sim \Pi$.
2. Vygeneruj iid vzorky $D_n = (Y_i, X_i)_{i=1}^n$ a jeden dodatečný pár (Y, X) z modelu p .

Tento mechanismus definuje sdílené rozdělení nad $(D_n \cup (Y, X), p)$ pro každé n . Skutečné rozdělení p_0 je ta realizace p , ze které skutečně pocházejí naše data, zpravidla je p_0 neznámá.

Pro každé n poskytuje výše popsany statistický model dobře definované sdružené rozdělení n -tice $(D_n \cup (Y, X), p)$. Na základě tohoto modelu lze $p_0(y | x)$ aproximovat pomocí posterior predictive distribution (PPD):

$$\pi(y | x, D_n) = P(Y = y | X = x, D_n),$$

kterou jsme již zmiňovali v předchozí sekci, uved' me její definici ještě jednou i zde a se zařazením do kontextu. Tím vzniká celá rodina PPD indexovaná n . Pokud prior Π faktorizuje nezávisle pro marginální složky $p(y | x)$ a $p(x)$, tj. rozdělení příznaků a rozdělení tříd jsou v prioru nezávislé, pak lze PPD dále zapsat jako:

$$\pi(y | x, D_n) = \int p(y | x) d\Pi(p | D_n), \quad (3.1)$$

kde $\Pi(\cdot | D_n)$ je tzv. *posterior*, což je podmíněné rozdělení p dané pozorovanými daty D_n , získaná Bayesovým pravidlem. Tento integrál říká v zásadě relativně jednoduchou věc: průměrujeme

$$p(y | x)$$

přes všechna možná p vážená jejich posteriorní pravděpodobnostmi, pak modely p , které jsou konzistentní s D_n dostanou větší váhu. Podmínka faktorizace prioru je spíše technická. Platí-li podmínka, pak když jsme viděli data D_n , říkají nám něco o $p(y | x)$, ale x -ová souřadnice testovacího bodu sama o sobě

nic neříká o $p(y | x)$. Pokud by totiž ta podmínka neplatila, potom by i testovací souřadnice x byla informativní pro $p(y | x)$, což pro náš případ nedává smysl. PPD $\pi(y | x, D_n)$ je tedy *posteriorní střední hodnota* podmíněných rozdělání $p(y | x)$, vážená tím, jak jsou jednotlivé modely p konzistentní s D_n .

PFN je numerická aproximace celé rodiny PPD $\{\pi(\cdot | \cdot, D_n), n \in \mathbb{N}\}$. Základním teoretickým poznatkem je, že PPD sama o sobě je pro každé n optimálním prediktorem v následujícím smyslu. Definiujme třídu všech podmíněných pravděpodobnostních funkcí takto:

$$\mathcal{Q} = \left\{ q : (\mathcal{Y} \times \mathcal{X})^{n+1} \rightarrow [0, 1] \mid \sum_{y \in \mathcal{Y}} q(y | \cdot, \cdot) = 1 \right\}.$$

Každé $q \in \mathcal{Q}$ je tedy funkce, která dostane n trénovacích párů (Y_i, X_i) a jeden testovací vstup $\mathbf{X}$, a vrátí distribuci přes $\mathcal{Y}$.

Věta 3.4.1. π z rovnice 3.1 splňuje:

$$\pi = \arg \max_{q \in \mathcal{Q}} \mathbb{E}_{\Pi}[\log q(Y | X, D_n)], \quad (3.2)$$

kde $\mathbb{E}_{\Pi}$ je střední hodnota přes $(Y, X) \cup D_n$ generované dle mechanismu v sekci 2.1.

Jinými slovy PPD π maximalizuje očekávanou podmíněnou log-likelihood přes všechny možné prediktory z $\mathcal{Q}$. To znamená, že to je nejlepší možný prediktor za daného prioru Π .

Dále navíc maximalizaci výrazu $\mathbb{E}_{\Pi}[\log q(Y | X, D_n)]$ lze ekvivalentně chápat jako minimalizaci očekávané KL divergence

$$\mathbb{E} \left[\text{KL} \left(q(\cdot | X, D_n) \parallel \pi(\cdot | X, D_n) \right) \right].$$

PPD π je tedy KL-optimálním prediktorem v $\mathcal{Q}$.

Abychom PPD aproximovali v praxi, natrénujeme model q_{θ} , kde $\theta \in \Theta$ jsou parametry (např. váhy neuronové sítě). To znamená, že pro každou hodnotu θ existuje celá rodina funkcí:

$$\{q_{\theta} : (\mathcal{Y} \times \mathcal{X})^{n+1} \rightarrow [0, 1], n \in \mathbb{N}\},$$

ale závislost na n v notaci explicitně neuvádíme. KL-optimální parametry jsou definovány jako:

$$\theta^* = \arg \max_{\theta \in \Theta} \mathbb{E}_{\Pi_N} \mathbb{E}_{\Pi}[\log q_{\theta}(Y | X, D_N)], \quad (3.3)$$

kde Π_N je tzv. *size prior*, tj. rozdělání nad velikostí trénovací množiny N . Střední hodnota přes N zajišťuje, že q_{θ^*} umí napodobit celou rodinu* PPD pro různá n , ne pouze její n -tý prvek. Pro model q_{θ} zpravidla neexistuje θ takové, že $q_{\theta} = \pi$ přesně. V tom případě rovnice 3.3 definuje *KL-optimální* aproximaci π ve třídě $\{q_{\theta} : \theta \in \Theta\}$, tj. nejlepší aproximaci, které je daná architektura schopna.

Dále lze ukázat následující teoretickou vlastnost. Střední hodnota v (3) se v praxi aproximuje průměrováním přes m iid datasetů, např. pomocí metody Monte Carlo. Konkrétně generujeme datasety $(Y_j, X_j) \cup D^{(j)}$ velikosti $N_j + 1$ s $N_j \sim \Pi_N$ dle postupu 2. Empirická verze optimalizačního problému pak je:

$$\hat{\theta} = \arg \max_{\theta \in \Theta} \sum_{j=1}^m \log q_{\theta}(Y_j | X_j, D^{(j)}). \quad (3.4)$$

Přesnost $\hat{\theta}$ jako aproximace θ^* závisí na počtu Monte Carlo vzorků m . Ale důležité je, že se dá ukázat $\hat{\theta} = \theta^* + O_p(m^{-1/2})$. Z toho plyne, že konvergence $\hat{\theta} \rightarrow \theta^*$ je v praxi zaručena.

Nagler (2023) ukazuje, že pokud je trénovací loss NLL (negative log-likelihood, viz Fáze 8) a model má dostatečnou kapacitu, optimální řešení konverguje k Bayesovské posteriorní prediktivní distribuci. To znamená, že správně natrénovaný PFN je teoreticky ekvivalentní analytickému GP posterioru.

3.4.2 Od PPD k PFN

V této sekci si ukážeme podrobněji jak spolu souvisí pojmy PPD a PFN, řekneme si zajímavé vlastnosti ohledně učení PPD, která spojují tyto dva nástroje, a jako důsledek popíšeme i vlastnosti učení samotného PFN. Uvažujme definici PPD 3.1. Posterior $\Pi(\cdot | D_n)$ je plně určen priorem Π . Jde o standardní Bayesovo pravidlo aplikované na nekonečnědimenzionální parametr p . Pokud jsou data D_n generována z p_0 , doufáme, že se posterior $\Pi(p | D_n)$ s rostoucím n soustředí okolo p_0 , a tím pádem $\pi(y | x, D_n) \rightarrow p_0(y | x)$. Avšak v tomto okamžiku čelíme velmi netriviálnímu problému – jak zvolit správný prior, aby to konvergovalo. Obecně existují celé články a knížky o tom, jak se vypořádat s tímto problémem, který se vyskytuje v praxi tu a tam. Platí totiž, že je třeba, aby Π měl dostatečně velký support a tím pokrýval dostatečně bohatou třídu funkcí. To nám pak totiž umožní efektivní inferenci. Např. pro případ GP s RBF kernelem bychom chtěli pokryt celý prostor všemožných tvarů té funkce, tj. aby model uměl najít správné hyperparametry v RBF kernelu. Tím pádem, když PPD dostane sadu bodů, dokáže nám říct, ze které konkrétní konfigurace GP s RBF kernelem pochází. Ale ani velký suport nemusí stačit. Prior může sice p_0 obsahovat ve svém supportu, ale dávat příliš velkou hmotnost nepříznivým oblastem prostoru $\mathcal{P}$, čímž může konvergence posteriorů probíhat velmi pomalu nebo vůbec. Avšak Nagler ve svém článku ukazuje, že PPD se umí učit i v situaci, kdy p_0 leží mimo support prioru $\mathcal{P} = \{p : \Pi(p) > 0\}$. To platí, za určitých podmínek.

Věta 3.4.2. Uvažujme prior Π . Necht' dále platí:

1. Existuje jedinečné $p^* \in \mathcal{P}$ takové, že

$$p^* = \arg \min_{p \in \mathcal{P}} \text{KL}(p | p_0), \quad \text{KL}(p^* | p_0) < \infty.$$

2. Pro každé $\alpha \in (0, 1/2)$ existují množiny $B_1, \dots, B_{J(\alpha)}$ takové, že

$$\mathcal{P} \subseteq \bigcup_{j=1}^{J(\alpha)} B_j, \quad \sup_{p, p' \in B_j} H(p, p') \leq 4(\alpha^2/2)^{1/\alpha}, \quad \sum_{j=1}^{J(\alpha)} \Pi(B_j)^\alpha < \infty,$$

kde $H(p, p')$ je Hellingerova vzdálenost mezi p a p' .

Pak existuje $p^* \in \mathcal{P}$ takové, že

$$\pi(y | x, D_n) \xrightarrow{n \rightarrow \infty} p^*(y | x) \quad \text{s. j.,}$$

pro P_0 s.v. (y, x) . Navíc p^* je KL-optimální aproximace p_0 v $\mathcal{P}$:

$$p^* = \arg \min_{p \in \mathcal{P}} \text{KL}(p | p_0).$$

První podmínka v této větě požaduje, aby v supportu prioru existovala jednoznačná KL-optimální aproximace p^* pravého modelu p_0 a KL divergence p^* vůči p_0 je konečná. Druhá podmínka je technickým požadavkem na to, aby prior nepřiděloval příliš velkou hmotnost oblastem daleko od p^* , prior nesmí být příliš rozptýlený v nežádoucích oblastech supportu. Sama o sobě věta tvrdí, jak se PPD učí. Konkrétně, že se učí tím lépe, čím víc dat máme, a snaží se naučit co nejlepší aproximaci p_0 dosažitelnou v $\mathcal{P}$. Pokud $p_0 \in \mathcal{P}$ (prior obsahuje pravý model): $p^* = p_0$ a PPD konverguje přímo k p_0 . Pokud $p_0 \notin \mathcal{P}$ (prior pravý model neobsahuje): PPD stále konverguje, ale k nejbližšímu $p^* \in \mathcal{P}$ v KL smyslu. Logicky čím větší je $\mathcal{P}$, tím víc se přibližuje p^* ke skutečnému p_0 .

Toto tvrzení nám tedy úplně řeší problém hledání správného prioru, na který jsme upozorňovali na začátku sekce. My totiž nepotřebujeme perfektní prior, nýbrž aby byl "dostatečně rozumný" ve smyslu předpokladů věty 3.4.2, a objem dat postupně ten náš odhad prioru opraví. Avšak PPD je ideální teoretický případ. Pokud bychom chtěli tyto vlastnosti použít např. u PFN, je zde několik nuancí. PFN je totiž pouze aproximací PPD, jak ukážeme dále, trénovaná na omezených datasetech, a proto tvrzení 3.4.2 nelze přímo aplikovat.

Podívejme se podrobněji na to, jak PFN aproximuje PPD. Již jsme si definovali vztah 3.4 a teď na něj budeme nahlížet jako na optimalizační problém. Na konečný výsledek $\hat{\theta}$ mají vliv čtyři faktory:

1. datový prior Π ,
2. prior velikostí vzorků Π_N ,
3. model q_θ ,
4. počet vzorků m .

Jelikož PFN je předtrénovaný model, třídu modelů $\{q_\theta : \theta \in \Theta\}$ lze považovat za fixní vůči m . Přesnost $\hat{\theta}$ jako aproximace θ^* pak plyne ze standardních výsledků empirické minimalizace vztahu: $\hat{\theta} = \theta^* + O_p(m^{-1/2})$. Tím máme hned vyřešený jeden z faktorů. Ostatní tři jsou mnohem zajímavější.

Pokud Π obsahuje pouze jednoduché modely, bude i optimální PFN q_{θ^*} produkovat jednoduché funkce (y, x) . Naopak, jednoduchá architektura $\{q_\theta : \theta \in \Theta\}$ nemůže těžit ze složitého prioru Π . Aby PFN dobře fungoval na různorodých úlohách, musí mít dostatečnou kapacitu jak architektura q_θ jako samotná, tak i prior Π .

Prior Π_N velikostí vzorků lze chápat jako regularizátor. Při tréninku (odkaz) se vzorkují datasety $D^{(j)}$ s náhodnou velikostí $N_j \sim \Pi_N$. Definujme KL–optimální parametr pro danou velikost vzorku:

$$\theta_n^* = \arg \max_{\theta} \mathbb{E}_{\Pi}[\log q_\theta(Y | X, D_n)].$$

PPD $\pi(y | x, D_n)$, kterou se snažíme aproximovat, se mění s n . Jako funkce od (y, x) roste její složitost s n . Pro $n = 1$ je PPD blízka průměrnému modelu v prioru a typicky téměř konstantní. Pro velká n je stále víc a víc komplexní. Analogicky θ_n^* preferuje složitější modely s rostoucím n . Optimalizací přes náhodné velikosti N_j výsledný θ^* průměruje $\theta_{N_j}^*$. Distribuce Π_N tak určuje, které velikosti datasetů jsou více signifikantní. To lze chápat jako regularizaci complexity modelu. Malé N_j nutí model k jednoduchým predikcím, velké N_j k složitým.

3.4.3 Učení PFN In–Context

V předchozí sekci jsme ukázali podstatnou vlastnost PPD, a to, že se se zvětšujícím se datasetem PPD přibližuje ke skutečné distribuci. Následně jsme ukázali, že PFN je pouhou aproximací PPD, jejíž kvalita závisí na určitých faktorech, a nelze s jistotou tvrdit, že pro něj platí stejné vlastnosti jako pro PPD a nelze na něj přímo aplikovat větu 3.4.2. Ukazuje se, že PFN se pořád může chovat jako PPD a zachovat její některé klíčové vlastnosti, jako např. již zmíněné tvrzení. Avšak v praxi to není tak jednoduché a jednoznačné. PFN se dokáže přiblížit k $p^*(y | x)$, a to i při relativně malém množství dat ($n \leq 1000$). Navíc se zachovává i to, že ani nemusíme pro tuto vlastnost najít perfektní prior. Přesto ale prozatím nemáme žádné teoretické důvody nebo předpoklady, aby toto byla pravda. V této sekci se pokusíme je odvodit.

V tomto okamžiku je výhodné přepnout se z bayesovského pohledu na frekventistický. Pro libovolnou velikost datasetu n při inferenci nahlížíme na předtrénovaný model $q_{\hat{\theta}}(y | x, \cdot)$ jako na nenatrénovaný frekventistický prediktor pro $p_0(y | x)$, což je funkce $(\mathcal{Y} \times \mathcal{X})^n \rightarrow \mathcal{P}_{\mathcal{Y}|\mathcal{X}}$, která mapuje dataset D_n na

podmíněnou distribuci. Parametry θ jsou pak jen hyperparametry tohoto prediktoru, vyladěné před tréninkem. Prior Π a Π_N jsou jednoduše distribuce nad úlohami, na kterých chceme, aby prediktor fungoval dobře. Dále rozepíšeme chybu predikce na bias a varianci:

$$q_\theta(y | x, D_n) - p_0(y | x) = \underbrace{q_\theta(y | x, D_n) - \mathbb{E}_{D_n \sim P_0^n}[q_\theta(y | x, D_n)]}_{\text{variance}} + \underbrace{\mathbb{E}_{D_n \sim P_0^n}[q_\theta(y | x, D_n)] - p_0(y | x)}_{\text{bias}}. \quad (3.5)$$

Již jsme řekli, že empiricky chyba predikce klesá spolu se zvětšujícím se n . Takže zkusme najít které strukturální aspekty PFN by to mohli vysvětlit.

Obecně ze struktury transformeru plyne, že jsou invariantní vůči permutacím vstupních dat (tj. symetrické), což je mimochodem jednou z výhod pro architekturu PFN dataset D_n je ze své podstaty množina, ne sekvence, takže permutační invariance je přesně ta vlastnost, kterou chceme pro i.i.d. vzorky.

Věta 3.4.3. Necht' $f : (\mathcal{Y} \times \mathcal{X})^n \rightarrow \mathcal{P}_{\mathcal{Y}|\mathcal{X}}$ je libovolný prediktor. Pak existuje jeho symetrizovaná verze $\tilde{f}$ taková, že pro každé pravděpodobnostní míry P :

$$\mathbb{E}_{D_n \sim P^n}[\tilde{f}(D_n)] = \mathbb{E}_{D_n \sim P^n}[f(D_n)], \quad \text{Var}_{D_n \sim P^n}[\tilde{f}(D_n)] \leq \text{Var}_{D_n \sim P^n}[f(D_n)]. \quad (3.6)$$

Tato věta říká, že takové symetrické prediktory jsou optimální z hlediska MSE. Toto je první opodstatnění faktu, proč chyba predikce pro PFN stále klesá.

Jsou tady i další strukturální vlastnosti prediktoru q_θ , které mají vliv na kvalitu predikce. Platí, že s větším D_n klesá vliv jednotlivých vzorků na výslednou predikci. Formálně předpokládáme, že existují $\alpha > 0$ a $L < \infty$ takové, že pro dostatečně velká n a s. v. datasety D_n, D'_n lišící se v jediném vzorku:

$$|q_\theta(y | x, D_n) - q_\theta(y | x, D'_n)| \leq Ln^{-\alpha}. \quad (3.7)$$

To nám umožňuje vyslovit tvrzení, které ukazuje, proč rozptyl během učení postupně mizí.

Věta 3.4.4. Necht' platí předpoklad 3.7, pak

$$|q_\theta(y | x, D_n) - \mathbb{E}[q_\theta(y | x, D_n)]| \lesssim n^{1/2-\alpha} \quad (3.8)$$

s vysokou pravděpodobností. Navíc pro $\alpha > 1/2$ platí $\lim_{n \rightarrow \infty} n^{1/2-\alpha} = 0$ a

$$q_\theta(y | x, D_n) - \mathbb{E}[q_\theta(y | x, D_n)] \xrightarrow{n \rightarrow \infty} 0 \quad \text{almost surely}. \quad (3.9)$$

Jinými slovy rozptyl postupně mizí s počtem dat n . Tak dostáváme, že hlavním pramenem chyby při inferenci není bias, kterého se už jen tak nezbavíme.

Ze vztahu 3.5 je vidět, že bias je určen chováním posloupností $\mathbb{E}[q_\theta(y | x, D_n)]$. Je logické, že bychom mohli předpokládat (nebo očekávat), že platí i tento vztah:

$$\mathbb{E}[q_\theta(y | x, D_n)] \xrightarrow{n \rightarrow \infty} \bar{q}_\theta(y | x),$$

kde $\bar{q}_\theta(\cdot | \cdot)$ je jakýsi zprůměrovaný prediktor, jehož konkrétní architekturu neznáme. Ale co můžeme říct s jistotou, tak že chování biasu hodně závisí na oné architektuře, jak ukazuje Nagler ve svém článku (REFERENCE), může růst, klesat, anebo být celou dobu konstantní. Co je avšak v našich silách – vyslovit nutnou podmínku pro mizení biasu. Má-li prediktor $q_\theta(\cdot | \cdot, D_n)$ mizející bias na dostatečně bohaté třídě funkcí, pak nutně musí být lokální. Lokální zde znamená, že např. k $q_\theta(y | x, D_n)$ by měly přispívat (asymptoticky) pouze vzorky $(Y_i, X_i) \in D_n$ s X_i blízko x . Tyto poznatky dává dohromady následující věta.

Věta 3.4.5. Necht' $\mathcal{P}$ je třída distribucí taková, že pro každé $p \in \mathcal{P}$:

$$\mathbb{E}_{D_n \sim p^n} [q_\theta(y \mid x, D_n)] \xrightarrow{n \rightarrow \infty} p(y \mid x). \quad (3.10)$$

Pokud platí 3.7, pak existuje posloupnost $\epsilon_n \rightarrow 0$ taková, že pro každé $\tilde{p} \in \mathcal{P}$ platí:

$$|q_\theta(y \mid x, D_n) - q_\theta(y \mid x, \tilde{D}_n)| \xrightarrow{n \rightarrow \infty} 0, \text{ s. j.} \quad (3.11)$$

kde $D_n = (Y_i, X_i)_{i=1}^n$ a $\tilde{D}_n = (Y'_i, X_i)_{i=1}^n$ s

$$Y'_i = \begin{cases} Y_i & \text{pokud } \|X_i - x\| \leq \epsilon_n, \\ \sim \tilde{p}(\cdot \mid X_i) & \text{pokud } \|X_i - x\| > \epsilon_n. \end{cases}$$

To znamená, že množina $\tilde{D}_n$ je poskládaná tak, že místo vzdálených od x bodů obsahuje náhodný šum, ale podstatné je, že nakonec ten šum (odlehle body) vůbec nemají vliv na výslednou predikci. To ovšem platí pro dostatečně bohatou množinu $\mathcal{P}$. Výsledek postrádá smysl, je-li $\mathcal{P}$ příliš malá. I pro bohatou $\mathcal{P}$ jde jen o nutnou, nikoliv postačující podmínku, konstantní prediktor $q_\theta = 1$ je lokální, ale jeho bias se s n nemění. Důležitý je ale důsledek pro bias-variance tradeoff: pokud bias mizí pro bohatou $\mathcal{P}$, prediktor může efektivně využít jen $\epsilon_n n = o(n)$ vzorků, takže podmínka 3.7 pravděpodobně neplatí pro $\alpha = 1$. Dále se ukáže, že lokalizace je kamenem úrazu pro transformer architekturu PFN. Attention váhy $a_j^{(h)}$ jsou výstupem SoftMax, tedy jsou vždy kladné pro všechny vzorky j , nikdy přesně nulové. Transformer tedy vždy váží nenulově i vzdálené vzorky. Přepis příznaků vzdálených bodů proto vždy predikci ovlivní, a lokalita ve smyslu věty 3.4.5 není splněna. Transformer tak garantuje mizení rozptylu, ale nikoli mizení biasu. Tato pozorování popíšeme podrobněji dále.

3.4.4 PFN transformer

Jelikož tato práce je věnovaná pohledu na PFN skrz architekturu Transformer (REFERENCE VASWANI), dává smysl se podívat na statistické vlastnosti této konkrétní architektury. Uvažujme tedy opět pro jednoduchost transformer s jednou vrstvou. Dataset $D_n = \{V_i\}_{i=1}^n$, kde $V_i = (Y_i, X_i) \in \{0, 1\} \times \mathbb{R}^d$, a testovací vektor $v = (0, x)$. Sít' je definována následujícími operacemi:

$$a_j^{(h)} = \text{SoftMax}\left(v^\top W_q^{(h)} V_1, \dots, v^\top W_q^{(h)} V_n\right)_j,$$

$$u' = \sum_{h=1}^H \sum_{j=1}^n a_j^{(h)} W_v^{(h)} V_j,$$

$$u = \text{LayerNorm}(v + u'; \gamma),$$

$$z' = W_{r,2} \text{ReLU}(W_{r,1} u; \gamma),$$

$$z = \text{LayerNorm}(u + z'; \gamma),$$

$$q_\theta(\cdot \mid x, D_n) = \text{SoftMax}(W_o z),$$

kde matice vah jsou $W_q^{(h)}, W_v^{(h)} \in \mathbb{R}^{(d+1) \times (d+1)}$, $W_{r,1}, W_{r,2}^\top \in \mathbb{R}^{m \times (d+1)}$, $W_o \in \mathbb{R}^{|\mathcal{Y}| \times (d+1)}$. V tomto případě parametr θ , který jsme všude uváděli v kontextu PFN v předchozích sekcích, sbírá všechny tyto matice.

To znamená, že $\theta = \{W_q^{(1)}, \dots, W_q^{(H)}, W_v^{(1)}, \dots, W_v^{(H)}, W_{r,1}, W_{r,2}, W_o, \gamma\}$ Operace SoftMax, LayerNorm a ReLU jsou definovány jako:

$$\text{SoftMax}(v) = \frac{\exp(v)}{\sum_j \exp(v_j)}, \quad \text{LayerNorm}(v; \gamma) = \gamma_1 \frac{v - \text{avg}(v)}{\|v - \text{avg}(v)\|_2 + |\gamma_2|} + \gamma_3, \quad \text{ReLU}(v) = \max(0, v),$$

kde $\exp$ a $\max$ působí po složkách. První dvě rovnice definují attention mechanismus s H hlavami (Vaswani et al., 2017). Ze součtu $a_1^{(h)} + \dots + a_n^{(h)} = 1$ plyne, že attention váhy tvoří pravděpodobnostní distribuci přes trénovací vzorky. Myšlenka je, že v každé hlavě attention váhy $a_j^{(h)}$ zdůrazňují konkrétní vzorky $V_j \in D_n$, konkrétně ty, které jsou "podobné" testovacímu vektoru v ve smyslu měřeném skalárním součinem $v^\top W_q^{(h)} V_j$. Každá attention hlava dovoluje jinou definici podobnosti prostřednictvím matice $W_q^{(h)}$. Intuitivně to funguje takto: transformer si při predikci pro x vyhledá v trénovacích datech vzorky, které považuje za relevantní, a jejich labely agreguje. Různé hlavy mohou sledovat různé aspekty podobnosti, jedna hlava třeba srovnává hodnoty X_i s x , jiná sleduje jiný rys vstupních vektorů.

Nás by také zajímalo, jaké vlastnosti má rozptyl a bias pro tuto architekturu, protože v předchozí kapitole jsme poznamenávali, že konkrétní vlastnosti těchto charakteristik se mění v závislosti na volbě konkrétní architektury.

Věta 3.4.6. Pro $\mathcal{X} = \{x : \|x\|_2 \leq K\}$ a omezené matice vah ($\|W_q^{(h)}\|_2, \|W_v^{(h)}\|_2, \|W_{r,1}\|_2, \|W_{r,2}\|_2, \|W_o\|_2 < \infty$) platí

$$|q_\theta(y | x, D_n) - \mathbb{E}[q_\theta(y | x, D_n)]| \lesssim n^{-1/2} \quad (3.12)$$

s vysokou pravděpodobností.

Velmi podobnou větu jsme již viděli v předchozí sekci. Dokonce tvrdí skoro stejné: rozptyl mizí nezávisle na parametru θ . Jde o strukturální vlastnost architektury, nikoliv výsledek tréninku. Důvodem je, že attention mechanismus nutně přiděluje každému vzorku váhu řádu $1/n$, takže vliv libovolného jednotlivého vzorku klesá s n . V případě biasu jsme již říkali, že ta situace je horší. Bias v případě transformeru totiž silně závisí na volbě θ . Označme $\bar{q}_\theta(y | x)$ limitní hodnotu predikce pro $n \rightarrow \infty$.

Věta 3.4.7. Za předpokladů platnosti věty 3.4.6 plyne

$$\mathbb{E}[q_\theta(\cdot | x, D_n)] \xrightarrow{n \rightarrow \infty} \bar{q}_\theta(\cdot | x), \quad (3.13)$$

kde $\bar{q}_\theta(\cdot | x)$ je definováno stejně jako $q_\theta(\cdot | x, D_n)$, ale s u' nahrazeným výrazem $\bar{u}' = \sum_{h=1}^H W_v^{(h)} \mathbb{E}_{V \sim g_h}[V]$,

kde $g_h(s) = \frac{\exp(v^\top W_q^{(h)} s)}{\mathbb{E}_{V \sim p_0}[\exp(v^\top W_q^{(h)} V)]} \cdot p_0(s)$.

To znamená, že v definici transformeru výše jsme nahradili výraz u' tím novým $\hat{u}'$. Navíc v definici $\hat{u}'$ se objevuje tzv. exponentially tilted function (česky exponenciálně vychýlená funkce). V tomto kontextu se zavádí jako asymptotická variace attention mechanismu. Tato funkce $g_h(s)$ zvyšuje pravděpodobnost těm hodnotám s , které se nejvíce podobají vektoru v ve smyslu $v^\top W_q^{(h)} s$, a snižuje pro zbylé body. Jinými slovy ten složitý vzoreček na obrázku ukazuje teoretickou situaci, co by se stalo, kdyby měl Transformer k dispozici nekonečně mnoho vzorků. Už nerozděluje váhy mezi jednotlivými datovými body, ale vezme celou spojitou distribuci dat a "vychýlí" ji celou směrem k té informaci, na kterou zrovna potřebuje upřít pozornost. Více formálně to znamená, že každá attention hlava h tak hodnotí určitý aspekt neznámé distribuce p_0 (charakterizovaný maticí $W_q^{(h)}$). Pokud jsou matice $(W_q^{(h)})_{h=1}^H$ dobře nastaveny, tyto jednotlivé pohledy rozlišují různé hodnoty příznaků.

Avšak g_h lokalizuje prediktor pouze do jisté míry. Ačkoli zvyšuje váhu vzorků podobných v , ale ne ve smyslu věty 3.4.5. Vzorky vzdálené od x stále nenulově přispívají, protože SoftMax nikdy nevytváří

přesně nulové váhy. Přepsání příznaků vzdálených vzorků proto vždy predikci změní, a tak lokalita podle 3.4.5 není splněna. Proto plyne, že bias transformeru obecně nemůže úplně zmizet. Limitní bias $\bar{q}_\theta(y | x) - p_0(y | x)$ přesto může být malý, pokud síť za attention vrstvou dokáže ze součtu aspektových souhrnů $W_v^{(h)} \mathbb{E}_{V \sim g_n}[V]$ zkonstruovat dobrou aproximaci p_0 . Relevance jednotlivých aspektů závisí na pravé distribuci p_0 . Méně relevantní aspekty mohou přispívat méně. Na malých vzorcích ($n = 1$) jsou všechny attention váhy $a_j^{(h)} = 1$, takže všechny aspekty přispívají stejnou měrou. To naznačuje, že bias může klesat v rozsahu velikostí, na které byl θ natrénován, nikoliv však za jejich hranicí, kde není důvod očekávat pokles biasu. Klíčovou roli hraje přítomnost více attention hlav ($H > 1$), spolupráce více hlav může efektivně napodobit mechanismus průměrování modelů. Dalším klíčovým nástrojem je větší počet attention vrstev. Navíc empirické testy ukazují, že na výslednou kvalitu predikce (a zmenšování biasu) hraje neposlední roli samotný trénink a jeho nastavení. Všechny tyto manipulační součástky tak dávají velký prostor pro manévr a různé jejich kombinace či nastavení mohou vést k velmi signifikantnímu poklesu biasu.

Dále lze různě upravovat strukturu PFN během inference či tréninku pro zlepšení lokality. Naším účelem je tedy nějakým způsobem donutit transformer se dívat na jednotlivé body co nejvíc lokálně a neuvažovat pro bod x příliš vzdálené hodnoty. Jedním z přímočarých způsobů je *post-hoc lokalizace*, kterou navrhuje Nagler. Pro predikci labelu v testovacím bodě x :

1. Sestrojí se redukováná trénovací množina $D_n(x)$ odstraněním všech vzorků kromě k_n nejbližších sousedů bodu x z D_n .
2. Predikuje se label maximalizující $q_\theta(\cdot | x, D_n(x))$.

Omezení na okolí x je ekvivalentní "roztažení" cílové funkce $p(y | \cdot)$ v okolí x , lokálně hladká funkce se chová přibližně jako konstantní. Konstantní funkce jsou pro q_θ snazší k aproximaci. Lokalizace tedy zlepšuje bias za cenu mírného zvýšení variance, prediktor pracuje s menší efektivní velikostí datasetu $k_n \ll n$.

Kapitola 4

Experimentální průzkum vlastností PFN

V této kapitole provedeme řadu experimentu, ve kterých budeme zkoumat a ověřovat různé hypotézy o tom, jak funguje PFN. Ačkoli Nagler se snaží ve své práci matematicky popsat principy PFN a naznačit jeho principy fungování, ale ve většině případu uvažuje jednovrstevný model a navíc vůbec nepopisuje, co PFN transformer ve výsledku vůbec dělá a jak fungují jeho vnitřní mechanismy. Proto se pokusíme tyto otevřené otázky probrat jestli ne skrz matematický aparát, tak alespoň pomocí empirických pozorování. Všechny experimenty budou provdny jenom pro architekturu typu transformer. Bude nás většinou zajímat jak vnitřní struktura PFN, tak i jeho některé vlastnosti jakožto nástroje pro Bayesovskou inferenci. Rovněž prozkoumáme mechanismy, jak PFN vyhodnocuje vstupní data a čím se tyto mechanismy liší od regrese pomocí Gaussovských procesů.

4.1 Vnitřní struktura PFN transformeru a jeho základní principy

Nejdříve uvedeme základní analýzu PFN transformeru. Zaměříme se zde na to, co přesně dělá se vstupními daty, podíváme se, zde se snaží nakopírovat stejné mechanismy jako GP, anebo zda dělá něco jiného. Experimenty jsme prováděli na dvou typech modelů. Oba sdílí identickou architekturu transformeru: 6 vrstev, 8 attention hlav, dimenze embeddingu 512, dimenze skrytých vrstev dopředné sítě 1024 a výstupní FullSupportBarDistribution s 1000 biny, celkem 14,14 milionu parametrů. Architektura je nastavena s parametry `features_per_group=1` a `attention_between_features=False`, tedy přesně tak, jak jsme ji popsali v předchozí kapitole pro případ 1D regrese. Oba modely byly trénovány na syntetických datech vygenerovaných z Gaussovského procesu s RBF kernelem, vstupní prostor $x \in [0, 1]$. Liší se však tím, z jakého prioru nad hyperparametry trénovací data pocházela, a tedy i délkou tréninku, neboť pro nefixní hyperparametry model potřebuje více času na učení.

Model se fixními hyperparametry:

Tento model byl trénován na GP s pevně nastavenými hyperparametry RBF kernelu: $\ell = 0,3$, `outputscale = 1,0`, $\sigma^2 = 10^{-4}$. Model se tedy učil aproximovat posterior jednoho konkrétního GP a trénink konvergoval za 100 epoch.

Model s náhodně vzorkovanými hyperparametry:

Model byl trénován na GP, jehož hyperparametry byly při každé dávce vzorkovány nezávisle z předem dané distribuce: $\ell \sim \mathcal{U}(0,05, 1,0)$, `outputscale` $\sim \text{LogNormal}(0, 0,5)$, $\sigma^2 \sim 10^{\mathcal{U}(-5, -2)}$. Tento model se tedy musí naučit generalizovat přes celou rodinu GP funkcí s různými korelačními délkami a amplitudami — jde o plnohodnotný meta-learning nad distribucí hyperparametrů. Právě proto vyžaduje podstatně delší trénink: model viděl data z nespočetně různých tvarů funkcí a musel se naučit rozpoznávat hyperparametry přímo z kontextových dat. Trénink trval 500 epoch.

Výsledky obou modelů porovnáváme v průběhu jednotlivých experimentů s referenčním analytickým GP posteriorem, který pro dané hyperparametry a kontextová data vrací přesné řešení. Začneme ovšem s případem fixních hyperparametrů. Pro model to je značné zjednodušení, přesně ví, co se má naučit, a jak se ukáže dále, velmi efektivně. Na tomto jednoduchém příkladě ukážeme hlavní principy inference této metody, abychom následně mohli přejít na těžší příklady.

4.1.1 Struktura attention matic

Začneme však s tím, že vykreslíme si jednotlivé vrstvy a podíváme se na vnitřnosti transformeru a jak se jeho vrstvami prochází tok dat. Attention matice je přirozené okno do toho, jak transformer interně organizuje informaci. Připomínáme, že v naší konfiguraci má model 6 vrstev a v každé vrstvě 8 attention hlav, přičemž každá hlava může sledovat jiný aspekt vstupních dat. Vizualizaci provedeme pro 100-epoch model na sekvenci délky 120 bodů: 20 trénovacích bodů a 100 testovacích bodů. Výsledkem je attention matice tvaru 120×120 , přičemž každý prvek a_{ij} říká, jak moc bod i (jako *query*) věnuje pozornost bodu j (jako *key*). Matici průměrujeme přes 8 attention hlav dané vrstvy, aby byl celkový obraz přehledný.

Protože víme, které pozice odpovídají trénovacím bodům (0–19) a které testovacím (20–119), lze matici přirozeně rozdělit na čtyři kvadranty:

	Key: Train	Key: Test
Query: Train	Train→Train	Train→Test
Query: Test	Test→Train	Test→Test

Kvadrant *Test→Train* je pro nás klíčový: říká, jak moc testovací body “čerpají” informaci z trénovacích dat při budování své predikce. Z pohledu GP inference bychom očekávali, že právě tento kvadrant bude dominantní — predikce v novém bodě x^* závisí na pozorovaných párech (X, y) , nikoli naopak.

Na obrázku 4.1 je vidět, jak se struktura attention matic vyvíjí přes vrstvy:

Vrstva 0:

vykazuje relativně rovnoměrné, distribuované attention váhy. Žádný kvadrant výrazně nedominuje a váhy jsou rozloženy plošně přes mnoho pozic. Tuto vrstvu interpretujeme jako *explorativní* fázi: model sbírá globální informaci o rozložení všech bodů v sekvenci bez toho, aby se specializoval.


Vrstvy 1–4:

attention postupně řídne — váhy se soustřeďují na méně pozic a zbytek klesá k nule. Vzory se stávají strukturovanějšími: kvadrant *Test→Train* začíná nabývat na intenzitě, zatímco *Train→Test* slábne. Tyto prostřední vrstvy zřejmě slouží k internímu zpracování a redistribuci informace — postupnému sestavování reprezentace, ze které bude moci poslední vrstva provést samotnou inferenci.

Vrstva 5:

(poslední) vykazuje nejzřetelnější vzor. Kvadrant *Test→Train* je jasně dominantní a strukturovaný, zatímco kvadrant *Train→Test* je téměř nulový. Tato asymetrie je přesně tím, co bychom čekali od GP inference: testovací body jsou podmíněny trénovacími daty, nikoli naopak.

Podstatné je, že tuto kauzální asymetrii model **neměl explicitně zakódovanou** — vyplynula přirozeně z optimalizace na syntetických GP datech. Kdybychom totiž model trénovali na datech bez kauzální struktury, attention by zůstala symetrická. Samotná existence asymetrie v poslední vrstvě je tak prvním experimentálním důkazem, že PFN provádí Bayesovskou inferenci — a nikoliv pouhý pattern matching nebo memorování trénovacích příkladů.



Obrázek 4.1: Attention matice pro všech 6 vrstev 100-epoch modelu (průměr přes 8 hlav) pro jednu konkrétní GP realizaci. Osa x : *key* pozice (na které body se díváme), osa y : *query* pozice (které body se dívají). Cyánová čára odděluje trénovací (0–19) a testovací (20–119) pozice. Světlejší barva odpovídá vyšší attention váze. Přesné hodnoty vah závisí na konkrétních vstupních datech, kvalitativní vzor (vrstva 0 distribuovaná → vrstva 5 s dominantním *Test*→*Train* blokem) je však stabilní.

4.1.2 Matematický rámec pro srovnávací experimenty

Než přistoupíme k samotným experimentům, je užitečné shrnout matematický aparát, který budeme v dalších sekcích potřebovat. Jde konkrétně o tři formule, jejichž vzájemný vztah je jádrem naší analýzy.

Posteriorní střední hodnota GP:

Po pozorování kontextových párů (X, y) je posteriorní střední hodnota Gaussovského procesu v novém bodě x^* dána vztahem:

$$\mu(x^*) = k(x^*, X)[K(X, X) + \sigma^2 I]^{-1} y,$$

kde $K(X, X)_{ij} = k(x_i, x_j)$ je kernelová matice a σ^2 je variance šumu. Klíčovou roli hraje inverze $[K + \sigma^2 I]^{-1}$, která *dekoreluje* blízké trénovací body — body, které si jsou podobné, si vzájemně “konkurují” a jejich kumulativní vliv je potlačen.

Nadaraya-Watsonův estimátor:

Nejjednodušší alternativou je Nadaraya-Watsonův (NW) estimátor, tj. normalizovaný váhovaný průměr trénovacích hodnot:

$$\hat{y}_{\text{NW}}(x^*) = \frac{\sum_i k(x^*, x_i) y_i}{\sum_i k(x^*, x_i)}.$$

NW se od GP liší právě absencí inverze kernelové matice — implicitně předpokládá, že trénovací body jsou vzájemně nekorelované. Blízké body proto dostávají neúměrně velkou kumulativní váhu a predikce je příliš hladká.

Attention mechanismus transformeru:

Attention v PFN počítá pro každý testovací bod x^* váhovanou kombinaci hodnot z trénovacích bodů:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V, \quad Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

Výsledná kernelová matice *závisí na datech*:

$$\text{Kernel}_{\text{attn}}(X) = \text{softmax}\left(\frac{XW_Q W_K^\top X^\top}{\sqrt{d_k}}\right).$$

Na rozdíl od fixního RBF kernelu se tato matice plně adaptuje na konkrétní vstupní sekvenci. Matice vah W_Q, W_K jsou naučeny z dat a mohou kódovat libovolnou strategii podobnosti.

Klíčová otázka, kterou budeme v následujících experimentech testovat, pak zní: *odpovídají attention váhy PFN normalizovaným RBF vahám, nebo se model naučil kvalitativně odlišnou strategii?* A pokud odlišnou — jak moc se jeho výstup blíží skutečnému GP posterioru oproti triviálnímu NW estimátoru?

4.1.3 Dělá PFN něco podobného jako GP s RBF kernelem?

V této sekci se zaměříme, zda se PFN transformer snaží napodobit chování RBF kernelu, a proto ho tak dobře aproximuje, anebo dělá něco jiného. Konkrétně pro každý testovací bod x^* porovnáme attention váhy a_i z poslední vrstvy (průměr přes 8 hlav) s normalizovanými RBF vahami:

$$w_i = \frac{k(x^*, x_i)}{\sum_j k(x^*, x_j)}.$$

Experiment provedeme pro 100-epoch model na $n_{\text{ctx}} = 20$ trénovacích bodech a 100 testovacích bodech, průměrem přes 5 nezávislých seedů.

Každá metrika je průměrována přes 5 nezávislých seedů, přičemž pro každý seed je vygenerována jedna GP sekvence délky 100 (prvních 20 bodů jako kontext, všech 100 jako testovací body). MSE je počítáno jako střední kvadratická odchylka mezi střední hodnotou predikce PFN a analytickým GP posteriorem přes všech 100 testovacích bodů. Korelace attention vs. RBF je pro každý testovací bod x^* spočítána jako Pearsonova korelace mezi attention vahami poslední vrstvy (průměr přes 8 hlav) a normalizovanými RBF vahami $\exp(-d^2/2\ell^2)$, zprůměrovaná přes všechny testovací body. Jako referenční baseline zahrnujeme rovněž Nadaraya-Watsonův estimátor: MSE(NW, GP) měří jeho odchylku od analytického GP posterioru a slouží jako dolní mez kvality nejjednoduššího kernel smoothingu. MSE(PFN, NW) pak kvantifikuje, nakolik se predikce PFN od NW liší — pokud $\text{MSE(PFN, NW)} \approx \text{MSE(NW, GP)}$, znamená to, že PFN a NW predikují zcela odlišné hodnoty, a tedy že PFN neprovádí prostý kernel smoothing. Naměřené hodnoty jsou shrnuty v tabulce 4.1.

Metrika	100-epoch model
Průměrná korelace Attn vs RBF	$0,374 \pm 0,270$
MSE(PFN, GP)	$0,000167 \pm 0,000096$
MSE(NW, GP)	$0,2099 \pm 0,1462$
MSE(PFN, NW)	$0,2092 \pm 0,1439$
Poměr MSE(NW)/MSE(PFN)	$\sim 1\,256\times$

Tabulka 4.1: Výsledky korelační analýzy attention vah vs. RBF kernelu a srovnání přesnosti predikcí. Průměr přes 5 seedů.

Z tabulky 4.1 vyplývají dvě zásadní pozorování. Za prvé, korelace attention vah s RBF kernelem je nízká ($0,374 \pm 0,270$) a s vysokou variabilitou, což naznačuje, že model *neprovádí* prostý RBF kernel-smoothing. Attention se naučila kvalitativně odlišnou strategii: jak je vidět na obrázku 4.2a, attention váhy jsou výrazně ostřejší než RBF — soustředí ují téměř veškerou váhu na nejbližší bod, zatímco RBF ji distribuuje plynule.

Za druhé, $\text{MSE(PFN, NW)} \approx \text{MSE(NW, GP)} \approx 0,21$ — vzdálenost mezi PFN a NW je přibližně stejně velká jako vzdálenost NW od GP. To znamená, že PFN sedí blízko GP posterioru, zatímco NW stojí daleko od obou: obě metody predikují zcela odlišné hodnoty. Kvantitativně je PFN o $1\,256\times$ přesnější než NW (poměr $\text{MSE(NW, GP)}/\text{MSE(PFN, GP)} = 0,2099/0,000167$). Na obrázku 4.2b je vidět, že NW systematicky přehlazuje oblasti s hustými trénovacími body, zatímco PFN posterior sleduje analytické GP řešení.

Proč je attention ostřejší než RBF? Attention hlavy nepotřebují počítat čistou kernelovou podobnost $k(x^*, x_i)$. Potřebují vypočítat to, co v kombinaci s ostatními hlavami a FFN vrstvami dá nejlepší aproximaci GP posterioru. A pro ten může být výhodnější ostřejší strategie — FFN pak snáze provede korekci odpovídající efektu K^{-1} .


Metodologická poznámka: co korelace Attn vs RBF skutečně říká:

Nízká korelace attention vah s RBF kernelem je platný a hodnotný závěr o chování *jedné komponenty* sítě. Existují však důvody, proč z ní nelze přímo usuzovat na celkové chování modelu.


Za prvé, attention není výstupní mechanismus — po ní následuje FFN, residuální spojení a v případě vícevrstvého modelu dalších pět bloků. I kdyby attention váhy v poslední vrstvě přesně odpovídaly normalizovaným RBF vahám, výstup PFN by se od NW stále lišil díky korekcím v FFN.

Za druhé, správnou referenční hodnotou pro porovnání *nejsou* čisté RBF váhy $k(x^*, x_i)$, ale efektivní GP váhy:

$$w_i^{\text{GP}} = \sum_j k(x^*, x_j) (K^{-1})_{ji}.$$



(a) Detail attention vah poslední vrstvy (průměr přes 8 hlav) pro vybraný testovací bod v porovnání s normalizovanými RBF vahami. Attention je výrazně ostřejší — koncentruje téměř veškerou váhu na nejbližší bod — zatímco RBF distribuuje váhu plynule. Korelace $0,374 \pm 0,270$.



(b) Srovnání predikcí PFN, Nadaraya-Watsonova estimátoru a analytického GP posterioru ($n_{\text{ctx}} = 20$). NW systematicky přehlazuje, PFN sleduje GP posterior s $\text{MSE } 167 \times 10^{-6}$ oproti MSE 0,21 u NW — rozdíl $\sim 1\,256\times$.

Obrázek 4.2: 100-epoch model: porovnání attention vah s RBF kernelem (nahore) a predikcí PFN, NW a GP (dole).

Tyto váhy jsou nelokální: blízké trénovací body si vzájemně konkurují a po aplikaci K^{-1} mohou mít menší váhu, než by odpovídalo RBF, zatímco vzdálené body mohou dostat kladnou či dokonce zápornou váhu. Nízká korelace attention s čistým RBF je tedy strukturálně očekávána — i perfektní GP aproximátor by vykazoval nízkou korelaci s RBF při tomto experimentálním designu.

Shrnutí: nízká korelace Attn vs RBF potvrzuje, že PFN neprovádí prostý kernel averaging. Kvalitu celkových predikcí vůči GP pak jednoznačně zachycuje poměr MSE $\sim 1\,256\times$ — a ten hovoří zcela ve prospěch PFN.

4.1.4 Jak přesný je PFN na skutečné GP realizaci?

Předchozí experiment porovnával PFN se syntetickým GP posteriorem — modelu jsme předložili trénovací body a srovnávali jeho predikci s analytickým řešením. Nyní přistoupíme k přísnějšímu testu: oba modely (PFN i GP oracle) budou predikovat *skutečné šumové hodnoty* neviděné GP realizace. Cílem je zjistit, jak se přesnost PFN vyvíjí s velikostí kontextu $n_{\text{ctx}} \in \{5, 10, 15, 20\}$.

Vygenerujeme kompletní GP realizaci délky 100 bodů. Z ní náhodně vybereme n_{ctx} bodů jako trénovací kontext; zbývající body slouží jako testovací cíl. MSE počítáme jako střední kvadratickou odchylku predikce od skutečných (šumových) y -hodnot přes testovací body. GP oracle zná správné hyperparametry ($\ell = 0,3$, $\sigma^2 = 10^{-4}$) a počítá analytický posterior. Metriky průměrujeme přes 5 seedů $\times$ 20 realizací = 100 instancí na každé n_{ctx} .

n_{ctx}	PFN (100-epoch)	GP oracle
5	0,0408 $\pm$ 0,0698	0,0340 $\pm$ 0,0635
10	0,0123 $\pm$ 0,0349	0,0112 $\pm$ 0,0360
15	0,0064 $\pm$ 0,0271	0,0028 $\pm$ 0,0036
20	0,0021 $\pm$ 0,0025	0,0017 $\pm$ 0,0011

Tabulka 4.2: MSE vůči skutečným hodnotám GP realizace jako funkce velikosti kontextu. Průměr přes 100 instancí (5 seedů $\times$ 20 realizací).

Diskuze:

Z tabulky 4.2 a obrázku 4.3 vyplývají tři pozorování.


Za prvé, GP oracle konzistentně dosahuje nižšího nebo srovnatelného MSE oproti PFN ve všech hodnotách n_{ctx} . To je očekávané: oracle zná přesné hyperparametry a provádí exaktní Bayesovskou inferenci, zatímco PFN je pouze aproximace.

Za druhé, rozdíl se zvětšuje se středním n_{ctx} . Při $n = 5$ je převaha GP oracle malá (0,034 vs 0,041); při $n = 15$ již GP dosahuje 0,003 oproti 0,006 u PFN. Příčinou je, že s více kontextovými body disponuje GP oracle přesnou inverzí kernelové matice K^{-1} , zatímco PFN tuto operaci pouze aproximuje. Při malém kontextu je K^{-1} málo informativní a obě metody jsou si blíže.

Za třetí, od $n = 20$ se obě metody přibližují: MSE(0,0021 vs 0,0017) jsou si prakticky rovnocenné. PFN tedy s dostatečným kontextem konverguje k chování GP oracle, aniž by explicitně invertoval kernelovou matici. Toto je jedním z klíčových empirických potvrzení toho, že PFN provádí plnou GP inferenci — nikoliv pouze kernel smoothing.


4.1.5 Konvergence střední hodnoty a kalibrace variance

Experiment 1 zkoumá, zda PFN správně předpovídá nejen střední hodnotu, ale také tvar profilu nejistoty (uncertainty) — tedy kde je model více a kde méně jistý. Trénovací data jsou omezena na oblast $x \in [0,3, 0,7]$ ($n_{\text{ctx}} = 20$), testovací body pokrývají celý interval $[0, 1]$ ($n_{\text{test}} = 100$). Výsledek



(a) MSE PFN (modrá) a GP oracle (zelená přerušovaná) jako funkce n_{ctx} . Chybové úsečky = ± 1 std přes 20 realizací. GP oracle mírně vede od $n = 10$, protože zná správné ℓ .

Experiment 6: vliv velikosti kontextu (stejná GP realizace)



(b) Vizualizace predikcí pro $n \in \{5, 10, 15, 20\}$. Červené body: kontextová data dostupná modelu; šedé body: skutečné neviděné hodnoty; modrá: PFN; zelená přerušovaná: GP posterior se správným ℓ . Všechny řádky vychází ze stejné GP realizace, liší se pouze velikostí kontextu. Od $n = 15$ obě křivky téměř splývají.


Obrázek 4.3: 100-epoch model: MSE a predikce jako funkce velikosti kontextu.

experimentu jsme opět dostali tímto způsobem – průměr přes 5 realizací $\times$ 5 seedů = 25 instancí celkem. Metriky kalibrace: $\text{Corr}(\hat{\sigma}_{\text{PFN}}, \sigma_{\text{GP}})$ (korelace směrodatných odchylek) a $\text{MSE}(\hat{\sigma}_{\text{PFN}}, \sigma_{\text{GP}})$ (absolutní chyba kalibrace). Dále uvádíme *ratio far/near* — poměr průměrné směrodatné odchylky (std) v oblasti extrapolace ($x \in [0, 0,2] \cup [0,8, 1]$) ke směrodatné odchylce v centru dat ($x \in [0,4, 0,6]$), který měří, jak výrazně model zvyšuje nejistotu mimo oblast trénovacích dat.

Střední hodnota PFN sleduje GP posterior s vysokou přesností v oblasti s daty. Mimo trénovací sadu ($x < 0,3$, $x > 0,8$) PFN správně konverguje k prioru (hodnota 0), stejně jako GP. Ojediněle, pro realizace s vysokou amplitudou ($|m_{\text{train}}| > 1,5$), dochází k neúplné konvergenci, GP se v takových případech chová identicky.

Metrika	Hodnota
$\text{Corr}(\text{PFN std}, \text{GP std})$	$0,9812 \pm 0,0252$
$\text{MSE}(\text{PFN std}, \text{GP std})$	$0,00376 \pm 0,00911$
Ratio far/near — PFN	$21,3 \times \pm 5,2 \times$
Ratio far/near — GP	$25,9 \times \pm 3,8 \times$

Tabulka 4.3: Experiment 1: kalibrace variance pro 100-epoch model (průměr přes 25 instancí).



(a) Srovnání střední hodnoty a variance PFN (modrá) a GP (zelená). Trénovací body v $x \in [0,3, 0,7]$, predikce v celém $[0, 1]$. PFN správně rozpoznává region extrapolace zvýšenou variancí.

Obrázek 4.4: Experiment 1 — 100-epoch model: konvergence střední hodnoty a kalibrace variance.

Diskuze:

Korelace $r = 0,98$ potvrzuje, že PFN správně identifikuje tvar profilu uncertainty tam, kde je nejistota větší a kde menší. $\text{MSE}(\hat{\sigma}) = 0,0038$ signalizuje, že absolutní kalibrace je přesná. *Ratio far/near* u PFN ($21,3 \times$) dosahuje přibližně 82 % dynamického rozsahu GP ($25,9 \times$): PFN tedy mírně podhodnocuje míru zvýšení uncertainty v regionu extrapolace, avšak kvalitativně chování zachovává. Toto je zásadní vlastnost: model bez explicitní reprezentace GP posterioru přesto generuje uncertainty, která odpovídá bayesovskému výpočtu.

Závěr

Text závěru....

Literatura

- [1] S. Allen, J. W. Cahn: *A microscopic theory for antiphase boundary motion and its application to antiphase domain coarsening*. Acta Metall., 27:1084-1095, 1979.
- [2] G. Ballabio et al.: *High Performance Systems User Guide*. High Performance Systems Department, CINECA, Bologna, 2005. www.cineca.it
- [3] J. Becker, T. Preusser, M. Rumpf: *PDE methods in flow simulation post processing*. Computing and Visualization in Science, 3(3):159-167, 2000.